# 1. Introduction

## 1.1. Information Retrieval and Web Search Engine:

1.1.1. 定义：Examines key aspects of information retrieval as they apply to search engines; web crawling, indexing, querying and quality of results

## 1.2. Whole process overview

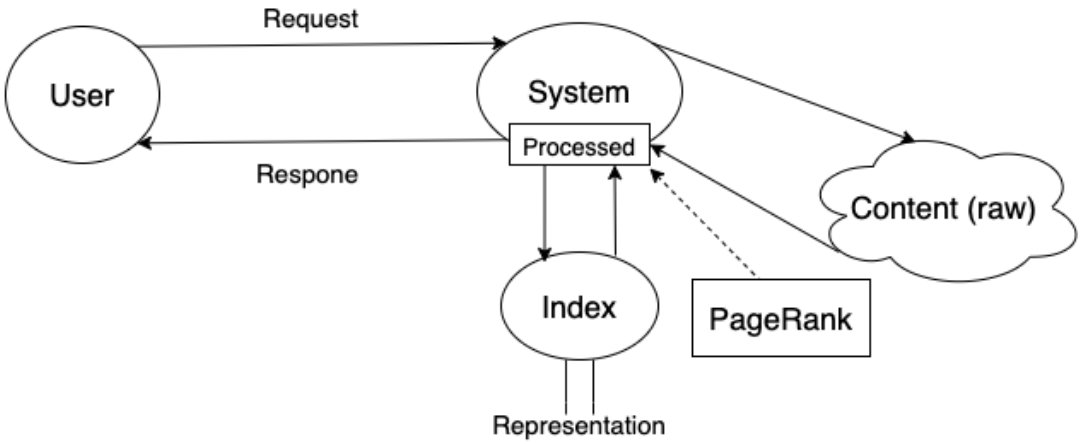


1.2.1. 文字描述：整个图包括两个流程：

1.2.1.1. user向system请求某些query, system根据index获得对应的raw content然后返回给user. query-> index -> raw content的过程称为processed; index又称为representation.

1.2.1.2. System定期进行爬虫取得raw content, 每一个raw content对应一个index存起来, 这个过程可能是insert, delete或者update.

1.2.1.3. 1.2.1.1和1.2.1.2是两个分别的流程, 互相之间独立运行.

1.2.1.4. Processed的目的: 加速用户搜索的速度

# 2. Search Engine Basics

## 2.1. Search Engine Elements

2.1.1. ***Spider*** (a.k.a. **crawler/robot**) - **builds corpus(维护语料库)**: Collects web pages recursively

2.1.2. **The *indexer* – creates inverted indexes**

2.1.3. ***Query processor* – serves query results**: Front end and Back end

## 2.2. Query Processing

2.2.1. Semantic analysis of the query includes

2.2.1.1. Determining the language of the query (确定语言)

2.2.1.2. Filtering of unnecessary words from the query (stop words) (把语气词去掉)

2.2.1.3. Looking for specific types of queries, e.g. (根据query中的词分类)

- Personalities (triggered on names)
- Cities (travel info, maps)
- Medical info (triggered on names and/or results)
- Stock quotes, news (triggered on stock symbol)
- Company info …

2.2.1.4. Determining the user's location or the target location of the query (用户地点)

2.2.1.5. Remembering previous queries (用户历史偏好)

2.2.1.6. Maintaining a user profile (将这次搜索纳入用户文档)

# 3. Crawlers and Crawling

## 3.1. 定义: A web crawler is a computer program that visits web pages in an organized way

## 3.2. Web Crawling Issues

3.2.1. **How to crawl?**

3.2.1.1. **Quality**: how to find the "Best" pages first (一般用BFS而不是DFS)

3.2.1.2. **Efficiency**: how to **avoid duplication**

3.2.1.3. **Etiquette**: behave politely by not disturbing a website's performance

3.2.2. **How much to crawl? How much to index? (crawl是要花钱的)**

3.2.2.1. **Coverage:** What percentage of the web should be covered?

3.2.2.2. **Relative Coverage:** How much do competitors have?

3.2.3. **How often to crawl? (crawl是要花钱的)**

3.2.3.1. **Freshness:** How much has changed?

3.2.3.2. **How much has really changed?**

## 3.3. Simplest Crawler Operation (crawling流程)

3.3.1. **Initialize** (begin with known "seed" pages) (**source code**)

3.3.2. **Loop**: Fetch and parse a page (用**queue**或者**stack**维护)

3.3.2.1. Place the page in a database

3.3.2.2. Extract the URLs within the page

3.3.2.3. Place the extracted URLs on a queue

3.3.2.4. Fetch a URL on the queue and repeat

## 3.4. Crawling的特点和面临的挑战

### 3.4.1. Crawling的过程可以distributed (可以处理大数据)

### 3.4.2. Challenges

#### 3.4.2.1. Handling/Avoiding malicious pages

- Some pages contain spam
- Some pages contain spider traps – especially dynamically generated pages

#### 3.4.2.2. Even non-malicious pages pose challenges

- Latency/bandwidth to remote servers can vary widely
- Robots.txt stipulations can prevent web pages from being visited
- How can one avoid mirrored sites and duplicate pages

#### 3.4.2.3. Maintain politeness – don't hit a server too often

#### 3.4.2.4. Robots.txt: The website announces its request on what can(not) be crawled by placing a robots.txt file in the root directory

★ **Example: Disallow**中包含的路径都是爬虫不能访问的

```
# robots.txt for http://www.example.com/

User-agent: *
Disallow: /cyberworld/map/ # This is an infinite virtual URL space
Disallow: /tmp/ # these will soon disappear
Disallow: /foo.html
```

## 3.5. Crawling Algorithm

Initialize queue (Q) with initial set of known URL's.
**Loop** until Q empty or page or time limit exhausted:
    Pop a URL, call it L, from the front of Q.
    **If** L is not an HTML page (e.g. .gif, .jpeg, ….)
        **continue** the loop
    **If** L has already been visited, continue the loop.
    Download page, P, for L
    **If** cannot download P (e.g. 404 error, robot excluded)
        **continue** loop
    Index P (e.g. add to inverted index and store cached copy)
    Parse P to obtain list of new links N.
    Append N to the end of Q
**End** loop

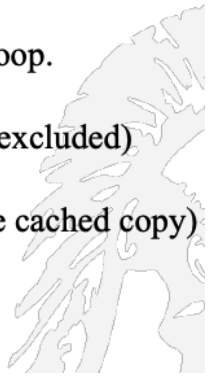

### 3.5.1. BFS (FIFO先进先出): 上面的例子就是用的BFS, 用的数据结构是queue

### 3.5.2. DFS (LIFO后进先出): 将上面例子的数据结构改为stack就是DFS

3.5.3. **Heuristically ordering (**启发式排序**):** 根据一些特定的条件对下一个爬的网页进行排序(e.g. A document that changes frequently could be moved forward)

## 3.6. Avoiding Page Duplication

3.6.1. To determine if a **URL** has already been seen:

3.6.1.1. Must store URLs in a standard format (discussed ahead)

3.6.1.2. Must develop a fast way to check if a URL has already been seen

3.6.2. To determine if a **new page** has already been seen,

3.6.2.1. Must develop a fast way to determine if an *identical* page was already indexed

3.6.2.2. Must develop a fast way to determine if a *near-identical* page was already indexed

## 3.7. Representing URLs

3.7.1. 问题: URL太多太长了, 直接存太耗费空间.

3.7.2. 方法1: **To determine if a new URL has already been seen**

3.7.2.1. hash on host/domain name

3.7.2.2. Use a **trie data structure (**字典树**)** to determine if the path/resource is the same as one in the URL database

3.7.2.3. 最直接的比较两个URL是否相同的方式: 逐个字符比较, 复杂度**O(nk)**, n是URL个数, k是URL最大长度

3.7.2.4. 用了trie之后的复杂度: **O(k)**

★ **Example of tire:**

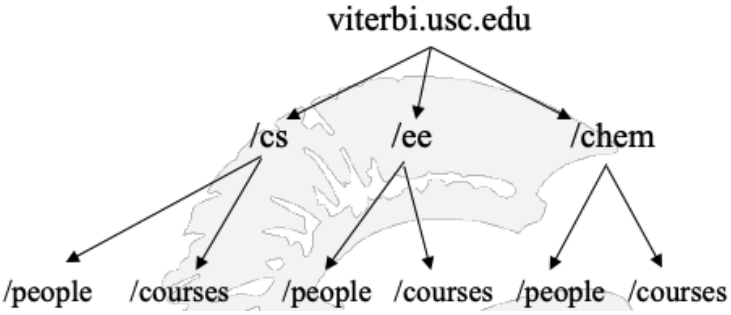


3.7.3. 方法2: **URLs are sorted lexicographically and then stored as a delta-encoded text file**

3.7.3.1. Each **entry is stored as the difference (delta) between the current and previous URL**; this substantially reduces storage

3.7.3.2. However, **restoring the actual URL is slower**, requiring all deltas to be applied to the initial URL

3.7.3.3. To improve speed, **checkpointing** (storing the full URL) is done periodically

## 3.8. Normalizing URLs

3.8.1. **Why Normalizing URLs is Important?** 很多相似的link指向同一个page但是一旦他们有一点点不同他们的hash值就会不同(e.g. http://www.google.com; http://www.google.com/; https://www.google.com)

3.8.2. **4 rules of Normalizing URLs**

3.8.2.1. **Convert the scheme and host to lower case.** The scheme and host components of the URL are case-insensitive.

★ **Example: HTTP**://www.**E**xample.com/ → **http**://www.**e**xample.com/

3.8.2.2. **Capitalize letters in escape sequences**. All letters within a percent-encoding triplet (e.g., "%3A") are case-insensitive, and should be capitalized.

★ **Example**: http://www.example.com/a**%c**2**%b**1b → http://www.example.com/a**%C**2**%B**1b

3.8.2.3. **Decode percent-encoded octets of unreserved characters.**

★ **Example:** http://www.example.com/**%7E**username/ → http://www.example.com/**~**username/

3.8.2.4. **Remove the default port.** The default port (port 80 for the "http" scheme) may be removed from (or added to) a URL.

★ **Example**: http://www.example.com**:80**/bar.html → http://www.example.com/bar.html

## 3.9. Avoiding Spider Traps

3.9.1. **Spider Traps定义: A spider trap is when a crawler re-visits the same page over and over again**

3.9.2. 最常见的**Spider Trap:** The most well-known spider trap is the one created by the use of Session ID's. A Session ID is often used to keep track of visitors, and some sites puts a unique ID in the URL (简单来说就是每个用户访问网页时会有一个ID, 有时候这个ID成为URL的一部分, 所以如果每次只改这一部分就会让爬虫一直重复在访问一个网页)

★ **Example:** www.webmasterworld.com/page.php?**id=264684413484654**

3.9.3. 解决方法**:**

3.9.3.1. For the crawler to be careful when the querystring "ID=" is present in the URL

3.9.3.2. Monitor the length of the URL and stop if the length gets "too long"

## 3.10. Handling Spam Web Pages

3.10.1. **Web Spam**的发展**:**

3.10.1.1. The first generation of spam web pages consisted of pages with a **high number of repeated terms**, so as to score high on search engines that ranked by word frequency

3.10.1.2. The second generation of spam used a technique called **cloaking**: When the web server **detects a request from a crawler, it returns a different page** than the page it returns from a user request. **The page is mistakenly indexed**.

3.10.1.3. A third generation, called a **doorway page**, contains **text and metadata chosen to rank highly on certain search keywords**, but when a browser requests the doorway page it instead gets a **more "commercially oriented" (more ads) page** (国内经典数字门户网站, 谁给的钱多推谁的网页)

## 3.11. Distributed Crawling

3.11.1. **Multi-Threaded Crawling: One bottleneck** is network delay in downloading individual pages. It is best to have **multiple threads** running in parallel each requesting a page from a different host. (在一台机器上多线程爬虫)

3.11.2. **Distributed Crawling Approaches:**

3.11.2.1. A **centralized crawler** controling a set of parallel crawlers all running on a LAN

3.11.2.2. A **distributed set of crawlers** running on widely distributed machines, with or without cross communication (MapReduce)

3.11.3. **If crawlers are running in diverse geographic locations, how do we organize them?**
→ Distributed crawlers must **periodically update** a master index (But incremental update is generally **"cheap"** because you need only send a **differential update**)

3.11.4. 优点**:**

3.11.4.1. **scalability:** for large-scale web-crawls

3.11.4.2. **costs:** use of cheaper machines

3.11.4.3. **network-load dispersion and reduction:** by dividing the web into regions and crawling only the nearest pages

3.11.5. 缺点**:**

3.11.5.1. **overlap:** minimization of multiple downloaded pages

3.11.5.2. **quality:** depends on the crawling strategy

3.11.5.3. **communication bandwidth:** minimization

3.11.6. **Distributed Crawling**三种策略**:**

3.11.6.1. **Independent:** no coordination, every process follows its extracted links (所有分不开的服务器单独爬虫, 合并的时候需要**deduplication, Very Fast**)

3.11.6.2. **Dynamic assignment:** a central coordinator dynamically divides the web into small partitions and assigns each partition to a process (一个主机来动态协调每个节点应该负责哪些link, 能避免**duplication**, 问题是主机可能**fail**)

3.11.6.3. **Static assignment:** Web is partitioned and assigned without a central coordinator before the crawl starts (在爬虫之前就好固定的访问link名单, 不需要动态协调所以不需要主机)

★ **Note:** 没有主机 **Static assignment** 如何交换不同 **partition**之间的 **links呢?** → BSP机制. 和MapReduce不同的是BSP中处理节点之间可以互相通信. (上课老师讲的例子就是罪犯逃到不同的地区时不同地区之间的警局会互相沟通交接)

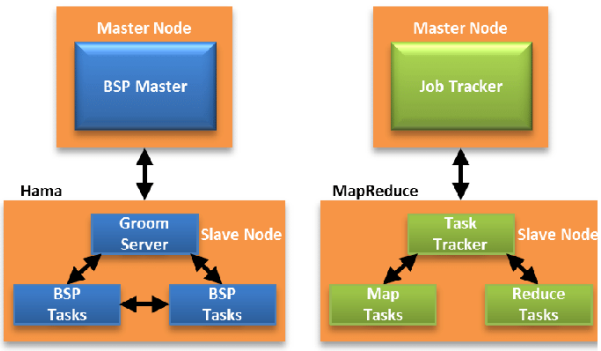


★ **Example:** 右图中如果Partition2要把ghi交还给Partition1, 就把ghi都移到左边去, 然后点开fg的连接. (注意这里是转移而不是复制,不然会造成**duplication**)

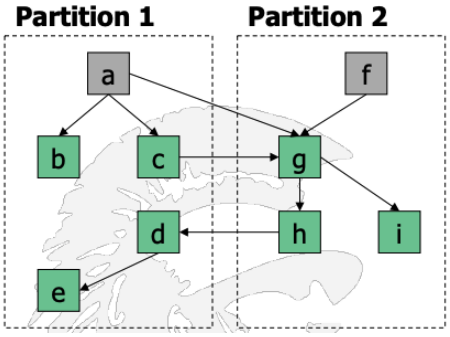


## 3.12. Keeping Spidered Pages Up to Date

3.12.1. **Periodically check** crawled pages for updates and deletions: Just look at LastModified indicator(在metadata中) (🌰: 假设我爬到一个网页的LastModified在五年前, 而它的index在我的数据库里对应的上一次爬虫是两年前, 那我这次就不需要update; 假设我爬到一个网页LastModified在五分钟前, 而index对应的上一次爬虫是五天前, 那我就需要update)

3.12.2. **Track how often each page is updated and preferentially return to pages which are historically more dynamic.** (有点像机器学习, 根据不同网页更新的频率来设置相应的爬虫更新频率)

3.12.3. **When a crawler replaces an old version by a new page, does it do it "in-place" or "shadowing"?** ("in-place"的意思是立马更新之前index对应的内容, "shadowing"的

意思是某个时间段内的这个link的所有更新都先存在一个temp index里, 到达某个时间后再覆盖掉真正的index的内容) → 这是一个**availability**和**consistency**的**tradeoff**. **"in-place"**可以保证**consistency**, 也就是用户每次查询的内容都一定是最新的, 但是速度会变慢因为后台一直要更新内容; 而**"shadowing"**可以保证**availability**, 因为在某个时间段用户查询的内容都是**old version**, 不需要修改所以速度很快, 但是**consistency**就不能保证了.

### 3.13. Conclusion

3.13.1. **Running multiple types of crawlers is best**

3.13.2. Updating in-place keeps the index current

## 4. Search Engine Evaluation

### 4.1. Precision, Recall, F1-score

| | | Predicted: Negative | Predicted: Positive |
|---|---|---|---|
| Actual | Negative | True Negative | False Positive |
| | Positive | False Negative | True Positive |

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall}$$

$$\text{precision} = \frac{|\{\text{relevant documents}\} \cap \{\text{retrieved documents}\}|}{|\{\text{retrieved documents}\}|}$$

$$\text{recall} = \frac{|\{\text{relevant documents}\} \cap \{\text{retrieved documents}\}|}{|\{\text{relevant documents}\}|}$$

4.1.1. **relevant**指的是真实相关**(actual true), retrieved**是认为相关**(predicted true)**

4.1.2. **F1-score(F-measure)**是**Precision**和**Recall**的**harmonic mean**

$$\text{F1 Score} = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

$$\text{Harmonic Mean Formula} = \frac{n}{\left(\frac{1}{x_1} + \frac{1}{x_2} + \frac{1}{x_3} \cdots\cdots \frac{1}{x_n}\right)}$$

4.1.3. **You can get high recall (but low precision) by retrieving all docs for all queries!** (容易理解, 如果我每次都把所有**docs**推给用户里面一定有他想看的, 但是没有意义, **precision**很低)

4.1.4. **In a good system, precision decreases as the number of docs retrieved (or recall) increases** (通过事实总结, 没有理论依据)

$$mAP = \frac{1}{n}\sum_{k=1}^{k=n} AP_k$$

$$AP_k = \text{the AP of class } k$$

$$n = \text{the number of classes}$$

### 4.2. Mean average precision

★ **Example:**

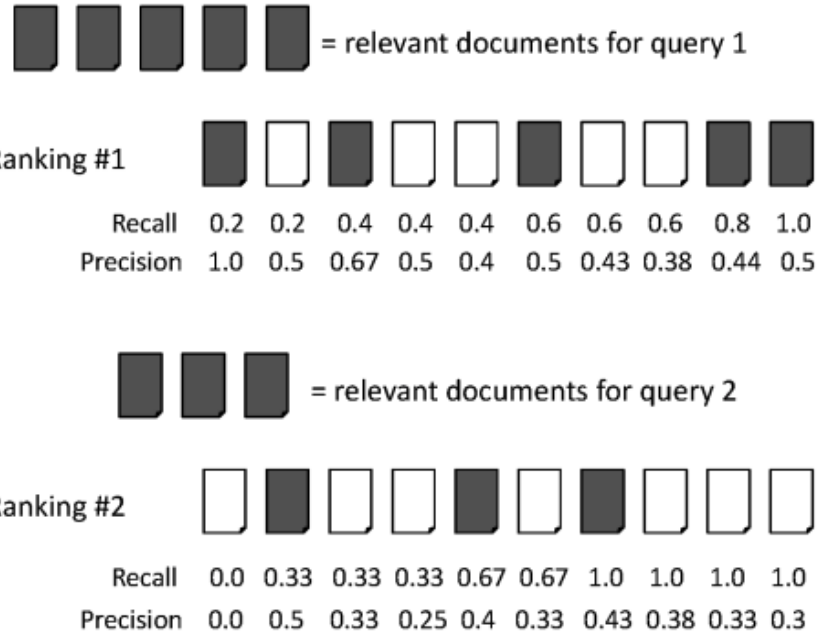


$$average\ precision\ query\ 1 = (1.0 + 0.67 + 0.5 + 0.44 + 0.5)/5 = 0.62$$
$$average\ precision\ query\ 2 = (0.5 + 0.4 + 0.43)/3 = 0.44$$

$$mean\ average\ precision = (0.62 + 0.44)/2 = 0.53$$

4.2.1. **mAP的缺点:**

4.2.1.1. **Each query counts equally**

4.2.1.2. If a relevant document never gets retrieved, we assume the precision corresponding to that relevant doc to be zero (this is actually reasonable)

4.2.1.3. mAP assumes user is interested in finding many relevant docs for each query

4.2.1.4. mAP requires many relevance judgments in the document collection

### 4.3. Discounted Cumulative Gain (DCG)

4.3.1. 定义: **Highly relevant documents appearing lower in a search result list should be penalized** as the graded relevance value is reduced logarithmically proportional to the position of the result

4.3.2. 公式: $DCG_p = \sum_{i=1}^{p} \frac{2^{rel_i}-1}{log_2(i+1)}$, 其中p为一个结果列表的排序位置, $rel_i$ 代表第i个位置上文档的相关度 (i通常情况下是rank)

★ **Example:** 假设搜索到6个结果, 其相关性分数分别是3,2,3,0,1,2. 求DCG

| i | $rel_i$ | log2(i+1) | $rel_i$ / log2(i+1) |
|---|---|---|---|
| 1 | 3 | 1 | 3 |
| 2 | 2 | 1.58 | 1.26 |
| 3 | 3 | 2 | 1.5 |
| 4 | 0 | 2.32 | 0 |
| 5 | 1 | 2.58 | 0.38 |
| 6 | 2 | 2.8 | 0.71 |

$DCG = 3 + 1.26 + 1.5 + 0 + 0.38 + 0.71 = 6.86$

### 4.4. Normalized Discounted Cumulative Gain (nDCG∈[0,1])

4.4.1. 首先对语料库中所有相关文档的相关性排序, 再通过位置生成最大可能的 DCG, 称为IDCG. 对于一个 Query, nDCG的公式$nDCG = \frac{DCG}{IDCG}$

★ **Example:** 沿用上面那个🌰, 假设我们实际召回了8个文档, 除了上面的6个, 还有两个结果. 假设第7个相关性为3, 第8个相关性为0. 那么在理想情况下的相关性分数排序应该是: 3, 3, 3, 2, 2, 1, 0, 0. 计算IDCG

| i | $rel_i$ | log2(i+1) | $rel_i$ / log2(i+1) |
|---|---|---|---|
| 1 | 3 | 1 | 3 |
| 2 | 3 | 1.58 | 1.89 |
| 3 | 3 | 2 | 1.5 |
| 4 | 2 | 2.32 | 0.86 |
| 5 | 2 | 2.58 | 0.77 |
| 6 | 1 | 2.8 | 0.35 |

$IDCG@6 = 3 + 1.89 + 1.5 + 0.86 + 0.77 + 0.35 = 8.37$

$nDCG = \frac{DCG}{IDCG@6} = \frac{6.86}{8.37} = 0.819$

### 4.5. Search engines also use non-relevance-based measures

4.5.1. **Click-through on first result** (看你推给用户的link有没有被用户点进去)

4.5.2. **A/B testing**: comparing two versions of a web page to see which one performs better. You compare two web pages by showing the two variants (let's call them **A** and **B**) to similar visitors at the same time. The one that gives a better conversion rate, wins!

## 5. Deduplication

**5.1.** 定义: De-duplication essentially refers to the identification of identical and nearly identical web pages and indexing only a single version to return as a search result

**5.2.** **Mirroring:** 镜像网站. Mirroring is the **single largest cause** of duplication on the web.

定义: Host1/a and Host2/b are mirrors if and only if for all paths p(所有子网页), http://Host1/a/p 存在, http://Host2/b/p 也存在, 并且内容几乎相同.

### 5.3. Duplication problems分类:

5.3.1. **Duplicate Problem: Exact match(**完全匹配**):**

5.3.1.1. 解决方案: compute **fingerprints** using **cryptographic hashing**(e.g. MD5)

5.3.1.2. Useful for URL matching and also works for **detecting identical web pages**

5.3.1.3. Hashes can be stored on sorted order for **logN** access(二分搜索)

5.3.2. **Near-Duplicate Problem: Approximate match(**近似相同**)**

5.3.2.1. 解决方案: compute the **syntactic similarity** with an **edit-distance measure**, and use a similarity threshold to detect near-duplicates (e.g. 相似度>80%就认为近似相同)

### 5.4. 通过Shingling检测两个网页是否相同:

5.4.1. **Shingling**概念: k-shingle (k-grams)是指文档中连续出现的 k 个字符构成的序列

★ **Example:** k=2, document $D_1$=abcab, 2-shingles $S(D_1)$ = {ab, bc, ca}, 这里的$S(D_1)$是一个集合

5.4.2. 怎么判断**k**多少合适？→ 选择一个总排列数比**buckets**数量大但又不会大很多的**k**

★ **Example:** 假设我们有20个不同的字符, shingles的总排列个数就是$20^k$, 那么现在我们对比4-shingles好还是9-shingles好

- 4-shingles: 可能的排列个数为$20^4=2^{17.3}$, 9-shingles: 可能的排列个数为$20^9=2^{39}$

- 假设我们用的hash tablen(bucket)用int来存, 一个int的范围在0~$2^{32}$-1

★ 我们更希望用9-shingles因为如果我们用**4-shingles,** 它的所有可能都要比我的空间小的多**($2^{17.3}$<<$2^{32}$)**, 我们会有很多剩余空间没被利用. 而**9-shingles**的所有可能要比$2^{32}$大, 但又不至于大很多, 这样我们完全利用了**int**的范围**,** 并且在把**$2^{39}$hash**成**$2^{32}$**的时候也不至于有很多重复以至于降低准确性

5.4.3. **Jaccard similarity:** $Sim(C_1, C_2) = \frac{|C_1 \cap C_2|}{|C_1 \cup C_2|}$

5.4.4. **Jaccard distance:** $Jaccard\ Distance = 1 - Jaccard\ Similarity$

5.4.5. 判断duplication流程:

5.4.5.1. 对每个网页内容生成k-shingles, 每个网页维护成一个集合

5.4.5.2. 将每个集合中的每个shingle分别hash成hash values

5.4.5.3. 通过相同的某些条件筛选出每个集合中的一些hash values(aka. **fingerprints**). 这一步主要是为了牺牲部分准确度来换取计算时间和空间

5.4.5.4. 通过这些fingerprints计算jaccard similarity, 一个很高的jaccard similarity就暗示了这些网页就是duplicated ($J(fingerprint(A), fingerprint(B)) > k$, the pages are similar)

★ **Example:**

- **Original text**
  - "Tropical fish include fish found in tropical environments around the world, including both freshwater and salt water species"
- **All 3-shingles (there are 16 of them)**
  - (Tropical fish include), (fish include fish), (include fish found), (fish found in), (found in tropical), (in tropical environments), (tropical environments around), (environments around the), (around the world), (the world including), (world including both), (including both freshwater), (both freshwater and), (freshwater and salt), (and salt water), (salt water species)
- **Hash values for the 3-shingles (sets of shingles are large, so we hash them to make them more manageable, and we select a subset)**
  - 938, 664, 463, 822, 492, 798, 78, 969, 143, 236, 913, 908, 694, 553, 870, 779
- **Select only those hash values that are divisible by some number, e.g. here are selected hash values using *0 mod 4***
  - 664, 492, 236, 908; ***these are considered the fingerprints***
- **Near duplicates are found by comparing fingerprints and finding pairs with a high overlap**

**5.5.** 通过**SimHash**检测两个网页是否相同**:**

5.5.1. **SimHash**和普通**hash**的区别**: documents that are nearly identical have nearly similar fingerprints that differ only in a small # of bits.** In other words, similar inputs lead to similar outputs (hash values), hence 'Sim'Hash; other hashing techniques,

eg. MD5, do not have this property (in other words, even a tiny change in the input leads to a huge change in the output). **(**简单来说就是**SimHash**中差别越小的文本得到的**hash value**越相近**)**

★ **Example:**

- **A hash function usually hashes different values to totally different hash values; here is an example**

  **p1 = 'the cat sat on the mat'**
  **p2 = 'the cat sat on a mat'**
  **p3 = 'we all scream for ice cream'**
  **p1.hash => 415542861**
  **p2.hash => 668720516**
  **p3.hash => 767429688**

- **Simhash is one where similar items are hashed to similar hash values (by similar we mean the bitwise Hamming distance between hash values is small)**

  **p1.simhash => 851459198**
  **00110010110000000011110001111110**
  **p2.simhash => 847263864**
  **00110010100000000011100001111000**
  **p3.simhash => 984968088**
  **00111010101101010110101110011000**

- **in this case we can see the hamming distance of the similar items (p1,p2)=4 is small whereas (p1,p3)=16 and (p2,p3)=12 are considerably larger**

5.5.2. 判断duplication流程:

5.5.2.1. comparing SimHash values is a great way to identify near-duplicates for 'n' documents, **comparing them all pairwise would take a long time [$O(n^2)$]**

5.5.2.2. as a shortcut, we can **sort their decimal representations and only compare adjacents** - this will identify similarities based on low-end bits; **but this will miss similarities based on the higher-end bits**; as an aside, we can look for one more possible low-bits near-duplicate by comparing the top-most and bottom-most values too, like in **Gray Code (Gray Code**的特点是前后两个二进制只会有一位是不同的**)**

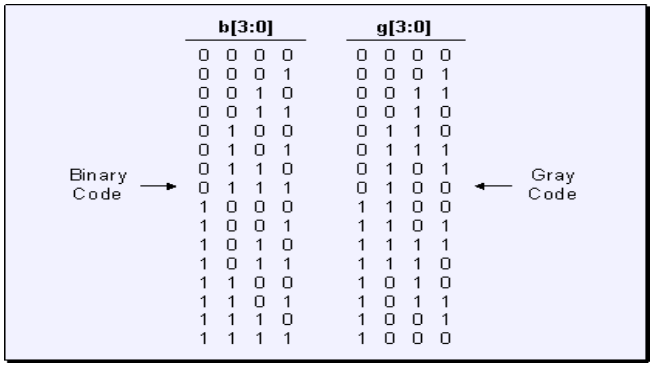

5.5.2.3. To fix the problem of missing finding high order bit similarities, we can **rotate** all the docs' bits identically to the right (so that **the high order bits (left) become a 'bit' (lol) lower**) to produce 'new' hashes, sort *those*, compare for near-duplicates

5.5.2.4. we can progressively spin right by 1 bit, 2 bits, 3 bits... to discover more and more similarities [we will rediscover existing similarities but ignore those]

5.5.2.5. note that **we can rotate left as well**

5.5.2.6. doing the above is **$O(n) + O(n\log n) = O(n\log n) < O(n^2)$**

★ **Example:**

- **consider the eight numbers and their bit representations**
- **1 37586 1001001011010010**
- **2 50086 1100001110100110 7 <--(this column lists hamming**
- **3 2648 0000101001011000 11 distance to previous entry)**
- **4 934 0000001110100110 9**
- **5 40957 1001111111111101 9**
- **6 2650 0000101001011010 9**
- **7 64475 1111101111011011 7**
- **8 40955 1001111111111011 4**

**if we sort them**

**4 934 0000001110100110**
**3 2648 0000101001011000 9**
**6 2650 0000101001011010 1**
**1 37586 1001001011010010 5**
**8 40955 1001111111111011 6**
**5 40957 1001111111111101 2**
**2 50086 1100001110100110 9**
**7 64475 1111101111011011 9**

**notice that two pairs with very smallest hamming distance hdist(3,6)=1 and hdist(8,5)=2 have ended up adjacent to each other.**

- **A problem:**
  - **there is another pair with a low Hamming distance, *hdist(4,2)=2* that have ended up totally apart at other ends of the list...**
  - **sorting only picked up the pairs that differed in their lower order bits.**

**'rotate' bits left twice**

**4 3736 0000111010011000**
**3 10592 0010100101100000 9**
**6 10600 0010100101101000 1**
**1 19274 0100101101001010 5**
**8 32750 0111111111101110 6**
**5 32758 0111111111110110 2**
**2 3739 0000111010011011 9**
**7 61295 1110111101101111 9**

**if we sort again by fingerprint**

**4 3736 0000111010011000**
**2 3739 0000111010011011 2**
**3 10592 0010100101100000 11**
**6 10600 0010100101101000 1**
**1 19274 0100101101001010 5**
**8 32750 0111111111101110 6**
**5 32758 0111111111110110 2**
**7 61295 1110111101101111 6**

**this time the (2,4) pair ended up adjacent**
**we also identified the (3,6) and (5,8) pairs as candidates again**

# 6. Spearman Correlation (SRC)

**6.1.** 公式: $\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$, 其中**$d_i$**表示**difference between the two ranks of each observation; n**表示**number of observations (**在统计学领域正常情况下**Spearman Correlation**的值在**[-1,1])**

**6.2. Modified Spearman Correlation:**

6.2.1. 问题: 普通的spearman correlation假定了比较的内容都是相容的只能存在rank排序的不同(overlap=100%), 但是实际情况下overlap可能不是100% (e.g. A = [o,m,a,b,c,f,g], B = [s,t,b,c,a,f,u]), 这时算出来的**spearman correlation**就不一定在**[-1,1]**了

6.2.2. 解决方法: 改公式为$\rho' = \rho * overlap\%$, 这样就可以保证$\rho'$在[-1,1]

★ 这里**saty**课上好像讲错了**?** 用了这个**modified SRC**在**search engine**的结果上计算也不能保证一定在**[-1,1].** 而且下面这个例子计算**SRC**的时候**rank**重新从**12345**排了**,** 而**hw1**中是没有**rank**重新排序的**.**

★ **Example:**

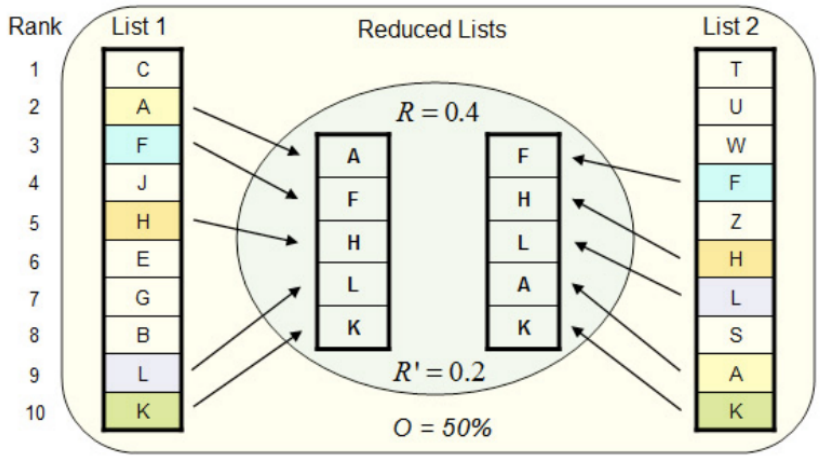


**6.3. Spearman Correlation in search engine:** 公式和普通的**spearman correlation**相同但由于有**overlap**所以值不一定在**[-1,1]**

★ **Note:** 这里在计算**spearman correlation**时用到的**rank**都是在原始**list**中的**rank,** 而不是上面那个🌰中的取出**overlap list**之后的新**rank**

★ **Example:** 假设我们从两个不同的搜索引擎用同一个query爬到两列结果

| Google | Bing |
|---|---|
| **a** | **a** |
| b | **f** |
| c | z |
| d | y |
| **e** | x |
| **f** | **g** |
| **g** | w |
| h | v |
| i | **e** |
| j | u |

很明显这里overlap是4/10, 对应的rank是{1-1, 5-9, 6-2, 7-6},因此得到的$d_i$分别为{0,-4,4,1}, 得到

$\rho = 1 - \frac{6*(0+16+16+1)}{4*15} = -2.30$ (这里用到的**rank**都是原始结果中的**rank**)

## 7. Information Retrieval

### 7.1. 目的: 读入用户的**queries,** 根据已有的数据库推荐给用户他们想要看的内容

**(要求在数据库里的存储格式是{word: [doc1,doc2 … dock]} (inverted index))**

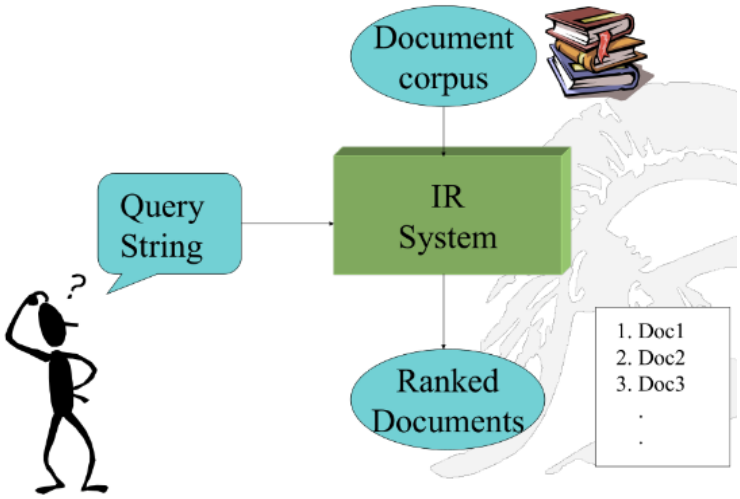

## 7.2. IR system的特点

7.2.1. A retrieval model specifies the details of:

7.2.1.1. Document representation (**vector of terms**)

7.2.1.2. Query representation (**vector of terms**)

7.2.1.3. Retrieval function (**TF-IDF** + **Similarity**)

7.2.2. Determines a notion of relevance (6.2.1.3)

7.2.2.1. Notion can be binary or continuous (i.e. ranked retrieval)

7.2.3. Three major Information Retrieval Models are:

7.2.3.1. Boolean models (set)

7.2.3.2. **Vector space models**

7.2.3.3. Probabilistic models

## 7.3. Document & Query representation

7.3.1. Documents和Queries都被表示成一堆keywords(aka terms)的集合

7.3.2. 语料库(vocabulary)是一个所有已知term的集合, 称为V

7.3.3. 假设我们用vector表示每个document和query

7.3.3.1. Size of V = Dimension

7.3.3.2. Document $D_i = (d_{i1}, d_{i2}, \ldots, d_{it})$, 其中$d_{ij}$表示第j个term在文档i中的权重(weight)是多少

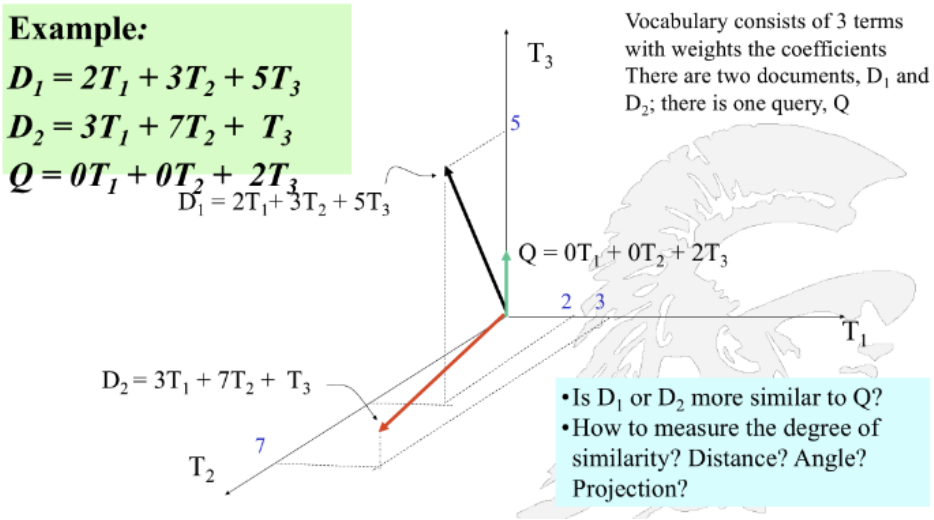


★ 如何计算这个**weight**呢**?** → **TF-IDF**

## 7.4. TF-IDF

7.4.1. TF-IDF定义: Measure of Word Importance. **Item profile for a document** = set of words with **highest** TF-IDF scores, together with their scores.

7.4.1.1. Term Frequency: $TF_{i,j} = \frac{f_{i,j}}{max_k f_{k,j}} \leq 1$, 进行了一次**normalized**

$f_{i,j}$ = frequency of term (feature) i in document (item) j

$max_k f_{k,j}$ = maximum occurrences of any term in document j

7.4.1.2. Inverse Document Frequency: $IDF_i = log_2(\frac{N}{n_i})$

$n_i$ = number of docs that mention term i

N = total number of docs

7.4.2. TF-IDF score: $w_{i,j} = TF_{i,j} \times IDF_i$

★ **Example:** 我们有$2^{20}$个document, term w出现在$2^{10}$个ducument里。

1. 假设w在document j里出现的次数是所有term里最多的。

   A: $TF_{w,j} = 1, IDF_j = log_2 \frac{2^{20}}{2^{10}} = 10,\ w_{w,j} = 1 \times 10 = 10$

2. 假设w在document i里出现的次数为1, 且文档里出现最多的term出现了20次。

   A: $TF_{w,i} = \frac{1}{20}, IDF_j = log_2 \frac{2^{20}}{2^{10}} = 10,\ w_{w,j} = \frac{1}{20} \times 10 = \frac{1}{2}$

7.4.3. 给定一个query, 它和一个document的分数$Score(q,d) = \sum(TF_{t,d} \times IDF_t)$, 其中 $t = Set(q) \cap Set(d)$

★ **Note:** in some cases we **normalize** each tf•idf value using the **L2** (sqrt of sum of squares), as opposed to **L1** ((absolute)sum) norm

★ 有了**TF-IDF,** 如何知道哪些**document**更应该推荐给用户呢**?** → **Cosine Similarity**

## 7.5. Cosine Similarity

7.5.1. 用Cosine Similarity的原因: 我们用vector表示query或者document, 它们之间的相似度就应该是两个向量之间的距离, 和向量的长短无关只和它们的方向有关 (**degree of similarity**)

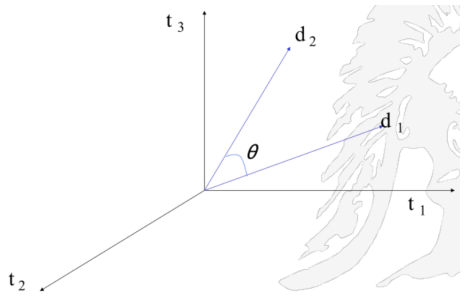


7.5.2. 朴素版本similarity: q和$d_j$之间的相似度就是他们的内积.

7.5.2.1. 公式$sim(d_j, q) = d_j \bullet q = \sum_{i=1}^{t} w_{ij} \bullet w_{iq}$, 其中$w_{ij}$表示term i和document j的权重, 而$w_{iq}$为term i和query之间的权重

7.5.2.2. 对于boolean vectors, 内积就表示哪些query中的terms在document中也出现了(aka size of intersection/Hamming distance)

7.5.2.3. 对于weighted term vectors, 内积表示所有共同出现的terms的加权乘积

★ **Example:**

**Binary:**

| | retrieval | database | architecture | computer | text | management | information |
|---|---|---|---|---|---|---|---|
| D | 1 | 1 | 1 | 0 | 1 | 1 | 0 |
| Q | 1 | 0 | 1 | 0 | 0 | 1 | 1 |

Size of vector = size of vocabulary = 7
0 means corresponding term not found in document or query

***similarity(D, Q) = 3*** **(the inner product)**

**Weighted:**

$D_1 = 2T_1 + 3T_2 + 5T_3$ $D_2 = 3T_1 + 7T_2 + 1T_3$
$Q = 0T_1 + 0T_2 + 2T_3$

$sim(D_1, Q) = 2*0 + 3*0 + 5*2 = 10$
$sim(D_2, Q) = 3*0 + 7*0 + 1*2 = 2$

7.5.2.4. 存在的问题: 文档的长度**(vector**的长度**)**会影响**similarity**(和7.5.1的要求不符)

7.5.3. 使用Cosine Similarity(相当于做了一个normalization):

7.5.3.1. **公式**: $similarity = cos(\theta) = \frac{A \cdot B}{||A|| ||B||} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} (A_i)^2} \times \sqrt{\sum_{i=1}^{n} (B_i)^2}}$

★ **Example1:**

$D_1 = 2T_1 + 3T_2 + 5T_3$ $CosSim(D_1, Q) = 10 / \sqrt{(4+9+25)(0+0+4)} = 0.81$
$D_2 = 3T_1 + 7T_2 + 1T_3$ $CosSim(D_2, Q) = 2 / \sqrt{(9+49+1)(0+0+4)} = 0.13$
$Q = 0T_1 + 0T_2 + 2T_3$

$D_1$ is 6 times better than $D_2$ using cosine similarity but only 5 times better using inner product.

★ **Example2:** A=[1,2,-1], B=[2,1,1], $similarity = cos(A, B) = \frac{1\times2+2\times1-1\times1}{\sqrt{1+4+1}\times\sqrt{4+1+1}} = \frac{1}{2}$

## 7.6. 完整TF-IDF + Cosine Similarity流程:

7.6.1. 将文档集合D中的所有文档都通过TF-IDF表示成vector, $d_j$表示第j个文档, 维护一个语料库V

7.6.2. 将每个query q都通过TF-IDF表示成vector

7.6.3. 对每个$d_j$, 计算q和$d_j$之间的score, $s_j = cosSim(d_j, q)$

7.6.4. 根据score从大到小对文档进行排序

7.6.5. 将top k个文档推荐给用户

★ **Note:** 时间复杂度**O(|V|·|D|)**, 当|V|和|D|很大的时候很慢! 如何加速**?** → **preprocessing** (对于每一个term, 提前算出它们相似度最高的若干个文档(把每个**term**当做一个长度为**1**的**query**), 存成一个preferred list → 对于一个t-term query, 取这t个term的preferred list的交集或者并集, 得到一个新的集合S → 将**S**当作新的文档集合去跑**7.6**)

### 7.7. TF-IDF + Cosine Similarity的缺点:

7.7.1. Missing semantic information (无法理解语义)

7.7.2. Missing syntactic information (无法理解语法 e.g. phrase structure, word order, proximity information)

7.7.3. **Assumption of term independence** (总结上面两点, 就是对待每个单词是独立的)

7.7.4. Lacks the control of a Boolean model (e.g. 搜索一个2-term query "A B", 用户可能要求A一定要频繁出现但是B没那么重要, 可以不出现在结果文档里; 但是在我们的算法中会平等地对待A, B所以会推荐A, B都出现但是都不频繁的文档)

## 8. Text Processing (Classification)

### 8.1. 模型:

- **Given:**
  - **A representation of a document *d***
    - **Issue: how to represent text documents.**
    - **Usually some type of high-dimensional space – bag of words**
  - **A fixed set of classes:**
    **$C = \{c_1, c_2, \ldots, c_J\}$**
- **Determine:**
  - **The category of *d* by generating a classification function, say *γ(d)***
  - **We want to build classification functions ("classifiers").**

8.1.1. 意义: 简单来说就是给定一个文档的向量, 将这个文档进行分类, 目的是方便推荐给有特定方向需求的用户

8.1.2. 🌰:

8.1.2.1. Standing Queries: 一直监视某些query的结果, 一旦有新的文档或者文档更新

就推送给用户 (本质上是监视某一个或多个类别)

8.1.2.2. Spam Filtering: 根据某些文本特性筛选出被归类为spam的email (事实上某一个email都可以根据用户需求被分类为某一类email自动进入某个folder)

★ **Example:**

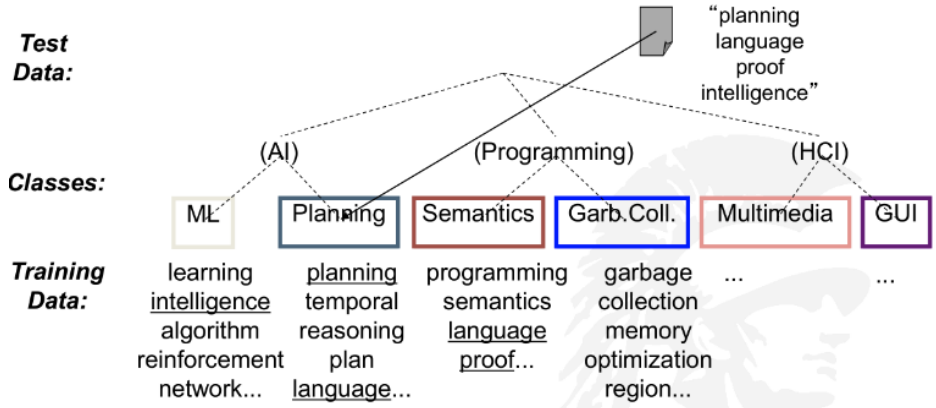


## 8.2. Classification Methods

8.2.1. Manual classification: 人为的给每个URL分类, 像是在维护一个图书馆. 需要experts才能很好地完成分类, 在数据规模很大的时候无法实现

★ **Note:** 这个方法最早由**Yahoo!**提出, saty在上课时对比了Yahoo!和Google的方法. Google的方法就是index法, 不需要分类, 在数据规模大的时候更有优势

8.2.2. Hand-coded rule-based classifiers:

8.2.2.1. 定义: 人为的制定某些规则进行分类 (e.g.如果你发的邮件符合某些特定的pattern, 你的邮件就会被NSA捕捉), 多用于news, government和enterprises.

8.2.2.2. 特点: 如果规则制定的好准确度就会很高, 但是随着时间规则可能要一直改变, 制定和维护好的规则是很expensive的 (1980年的规则用在现在可能很差)

8.2.3. **Supervised learning**:

8.2.3.1. 逻辑模型:

- **Given:**
  - **A document *d***
  - **A fixed set of classes:**
    **$C = \{c_1, c_2, \ldots, c_J\}$**
  - **A training set *D* of documents each with a label in *C***
- **Determine:**
  - **A learning method or algorithm which will enable us to learn a classifier *γ***
  - **For a test document *d*, we assign it the class**
    **$\gamma(d) \in C$**

8.2.3.2. Naive Bayes: 假定每个类别之间没有关联性 (比如一个水果具有weight, shape, smell等属性, 但它们之间我们假定是互相没有联系的, 也就是水果的shape不会影响它的smell)

8.2.3.3. K-Nearest Neighbors (KNN): 把所有objects作为向量, 通过最近的**K**个邻居的类别投票出自己的类别 (**K**绝大多数情况下是奇数以保证不会出现平局)

8.2.3.4. Support-vector machines(SVM): 把所有objects作为坐标点, 根据已知点的类别构造出一个**barrier**来区分所有点, 目标是尽可能把属于同一类别的点都分在同一边 (barrier可以是直线, 曲线, 超平面等, 取决于类别数量和feature数量)

★ **Note:** 上课的时候saty说KNN和SVM都是解决二分类问题的, 但其实他们都可以解决多分类问题, 可能只是他简化了 (都以spam email分类为例)

8.2.4. Many commercial systems use a **mixture** of methods **(ensemble learning)**: 先用多种模型跑同一个object看得到的分类, 然后根据结果结合experts给出的分类最后决定这个object属于哪一类

8.2.5. Feature特点: Supervised learning classifiers **<u>can use any sort of feature</u>** (并不局限于words. URL, email address, network features都可以作为feature)

## 8.3. Naive Classification representation

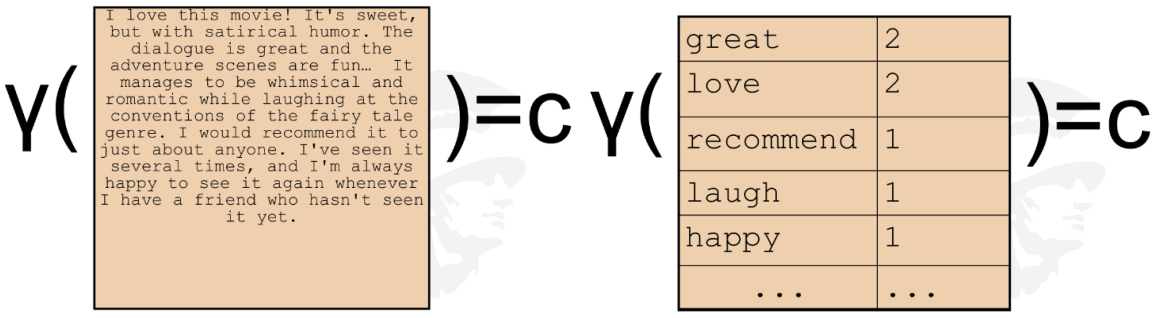

8.3.1. 过程: 得到一段话以后统计每个word出现的次数, 每个word作为一个feature给模型得到一个class

8.3.2. 特点: 只用word作为feature并且每个word都统计 (不管stop words)

8.3.3. 问题:

8.3.3.1. 存在noise: 很多stop words的出现其实在段落中是没有意义的, 但是会影响模型的学习

8.3.3.2. 可能导致overfitting: 过多feature会导致模型学习到的东西不够robust

8.3.4. 改进方法: **Feature Selection** (删去**stop words**之后只用**most common terms**来训练)

## 8.4. Evaluating Categorization

8.4.1. 常用Meatures: precision, F1 score, **classification accuracy**

8.4.1.1. **classification accuracy**: $\frac{r}{n}$, 其中n为测试文档总数, r为分类正确的文档数

## 8.5. Naive Bayes

8.5.1. 一个应用: **SpamAssassin**

8.5.1.1. 过程: 得到一个邮件以后通过某些feature判断它是一个spam email的可能性

8.5.1.2. 特点: feature不仅限于words, 还用blacklist (黑名单), hand-crafted text pattern (符合某些结构的邮件很可能是spam)

8.5.2. 优点:

8.5.2.1. **Very fast learning and testing** (不需要神经网络)

8.5.2.2. **Low storage requirements** (基本上只需要存一张概率表)

8.5.2.3. **Very good in domains with many equally important features** (因为Naive Bayes不能对feature添加重要性这个概念)

8.5.2.4. **More robust to irrelevant features than many learning methods (independent**

## 8.6. Classification using Vector Space

8.6.1. Vector Space:

8.6.1.1. 每个文档视为一个vector, 每个component是一个term

8.6.1.2. 通常情况下都被normalize成单位长度 (回顾7.5)

8.6.2. 可以分类的前提:

8.6.2.1. 训练集中documents in the same class form a **contiguous region of space** (同一类的**documents**不会分散在空间距离很大的位置**,** 并且有很好的形状)

8.6.2.2. 训练集中documents from different classes don't overlap **much** (极少情况下会

有**overlap,** 即某个**document**同时属于多个类别)

8.6.3. 目标: build surfaces to delineate classes in space

8.6.4. **Rocchio Classification (linear classifier)**

8.6.4.1. Centroid公式:

$\bar{\mu}(c) = \frac{1}{|D_c|}\sum_{d\in D_c}\bar{v}(d)$, 其中

$D_c$是c这个类别所有的documents的集合, v(d)是某个document的空间向量 (其实就是找出所有向量的平均方向)

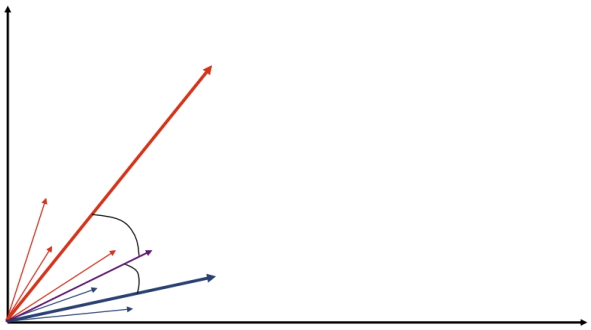

8.6.4.2. 过程: 每个类别形成自己的一个**centroid,** 当一个新的文档进来分类的时候**,** 比较它和所有**centroids**之间的距离**,** 选择**nearest**的那个一个**centroid**对应的**class**作为这个文档的**class (**如果恰好距离相等就同时属于多类**)**

8.6.4.3. 特点:

- 在**text classification**里效果很好, 但是之外的应用很少, 总体比Naive Bayes差
- **Cheap to train and test documents**
- It does not guarantee that classifications are consistent with the given training data

8.6.5. **KNN (non-linear classifier)**

8.6.5.1. 过程: 每个文档作为一个向量**,** 一个新的文档进来时找出离它最近的**k**个邻居进行投票**,** 得票最多的**class**作为新文档的**class (**尽可能设**k**为奇数防止平局情况**,** 万一真平了就同时属于多类**)**

8.6.5.2. 特点:

- **Case-based, Memory-based learning**
- **Lazy learning (**每次只需要计算**distance; no need for training)**
- ★ 💥💥**Exam**题目**(saty**上课说的**):** 已知我们算距离的公式$\sqrt{(x_1-x_2)^2+(y_1-y_2)^2}$, 每次得到一个新的文档就要重新计算k次这个公式, 有什么办法可以加速吗**?**
  - ➢ 答案: 不计算根号. 因为我们最后是比较距离而不是真正需要这些距离**,** 有没有根号没区别 (有点无厘头, 一个根号能省多少时间?)
- **No feature selection necessary**

- **No training necessary**
- 对于**large number of classes**能很好地**handle**
- **Small changes to one class can affect other classes**
- **Very expensive at test time** (要算距离)
- **In most cases accuracy > Naive Bayes and Rocchio**

8.6.5.3. 必要前提条件: **contiguity hypothesis** (Documents in the same class form a **contiguous region** and regions of **different classes do not overlap**. 详见8.6.2)

★ 如果出现了不满足**contiguity hypothesis**的情况怎么办**?** → 用**kernel trick**把它在转换维度变成**contiguity hypothesis**

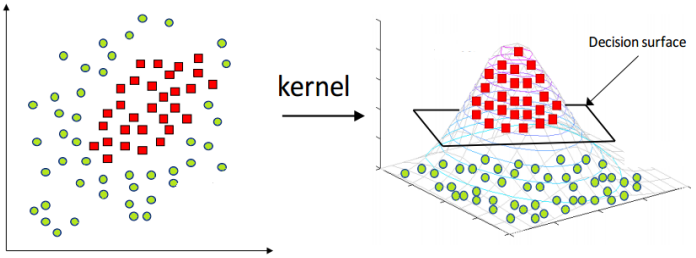


★ 如果找不到合适的**kernel function**怎么办**?** → **neural network** (相信玄学😅)

8.6.6. 对比KNN和Rocchio在**polymorphic categories**的效果:

8.6.6.1. **Polymorphic Categories:** 多态性分类 (🌰: 假设我有一个blog是关于旅行的, 但是在这个blog中我大部分时间在介绍旅行过程中的美食, 那么这个blog应该被归类为旅行、美食, 而不单单是一个类别)

★ 为什么**Rocchio**在**polymorphic categories**上效果不好**?** → **Rocchio**本质上把每个类别的所有个体都糅合成了某一个特质, 从而缺失了个体的特征**.** 我们回顾**8.6.4.2**中的内容**,** 只有在一个**doc**到多个**centroid**的距离完全相等时我们才认为这个**doc**属于多个类别**,** 这个概率是很低的

★ 为什么**KNN**在**polymorphic categories**上效果比**Rocchio, Naive Bayes**都好**?** → **KNN**本质上是个体与个体之间的比较**,** 找到和自己最像的**k**个个体**.** 因此并不是用一个**polygon**来描述每个个体

## 8.7. Bias-Variance Tradeoff (💥💥Exam题目 Why have to tradeoff???)

8.7.1. KNN has **high variance** and **low bias**

8.7.2. Rocchio/Naive Bayes has **low variance** and **high bias**

8.7.3. 尝试理解Bais和Variance:

8.7.3.1. **Bias**偏差是预测值与实际平均值的差值. 想象一下你可以多次重复构建整个

模型的过程: 每次收集一波新的数据并进行新的分析, 创建一个新的模型. 由于潜在数据的随机性, 所得到的这些模型将具有一系列预测值. 偏差就是衡量总体上这些模型的预测和真正正确值的偏差.

8.7.3.2. **Variance**方差是给定数据点的模型预测的波动性. 再次想像一下你可以多次重复整个建模过程. 方差是不同模型的预测结果对于一个固定点的变化多少.

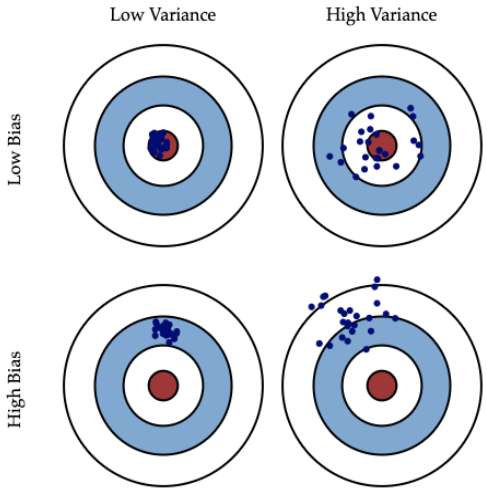


8.7.3.3. 以上面这个靶子图为例: 中间的红心是正确值. 一个点就代表了一次测试.

- 如果一个模型有低偏差和低方差(左上), 那么我无论给定数据集的哪个部分去测试, 得到的预测值都差不多且接近正确值
- 如果一个模型有低偏差和高方差(右上), 那么我给不同的数据集部分就会得到比较分散但是都比较接近正确值的预测值
- 如果一个模型有高偏差和低方差(左下), 那么我给不同的数据集部分就会得到比较集中但是都离正确值比较远的预测值
- 如果一个模型有高偏差和高方差(右下), 那么我给不同的数据集部分就会得到比较分散且都离正确值比较远的预测值

8.7.3.4. 根据上面的分析, 理论上最好的模型是符合具有低偏差和低方差特点的. 但是我们做得到吗? → 不行.

★ 为什么不能同时获得低偏差和低方差?

- 在机器学习中, **high bias**意味着模型没有学到数据的真实分布特点, 这是一种欠拟合**underfitting (high bias → underfitting)**
- 而**high variance**意味着模型只专注于一部分数据的分布特点, 这是一种过拟合**overfitting (high variance → overfitting)**
- 理论上如果我们训练的数据完全符合完整数据的分布特点, 那么只要模型的复杂度够高就能达到低偏差和低方差, 但现实的数据基本上都有**noise**,

并且是很多noise. 因此高复杂度的模型就意味着它还会拟合noise, 当然就造成了high variance

- 由上可得, 现实世界里增加深度学习系统的复杂度, 系统的Bias会减少, 而方差(Variance)会增加. 它们此消彼涨. 你不能同时减少它们, 这一点是Bias-Variance Tradeoff的基础

8.7.3.5. 因此, 一个算法越强调平均, 整体, 那它就越可能有**low variance**和**high bias**; 反之, 一个算法越强调个体, 那它就越可能有**high variance**和**low bias**

★ **Example1: Bias.** 分别用线性回归(左)和非线性回归(右)拟合到非线性模式的数据集. 结果说明了线性回归学不到非线性的特点, 因此**Bias**很大.

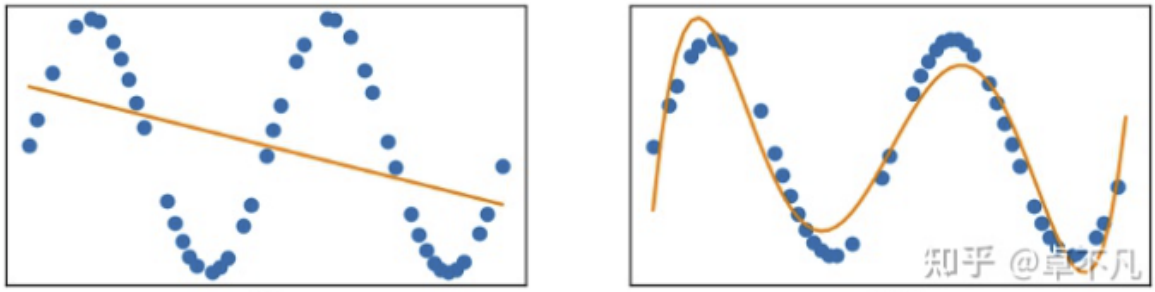


★ **Example2: Variance.** 分别用线性回归(左)和非线性回归(右)拟合到非线性模式的不同部分数据集. 结果说明了右边的模型过于复杂, 导致在不同的数据集的部分中的拟合曲线差别很大, 因此**Variance**很大. 想象假设以右边第一行数据作为训练集, 右边第二行的点作为测试集, 那么第一行的曲线就拟合不到测试集的点了, 这时候就是overfitting

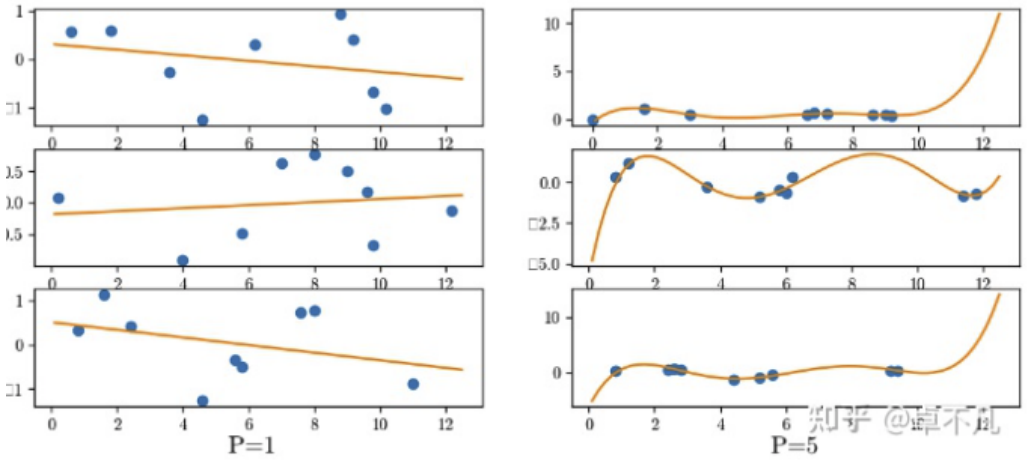


8.7.3.6. Bias-Variance Tradeoff曲线. 我们的目标就是找到optimal balance使total error最小, 过小的bias和过小的variance都不是我们想要的

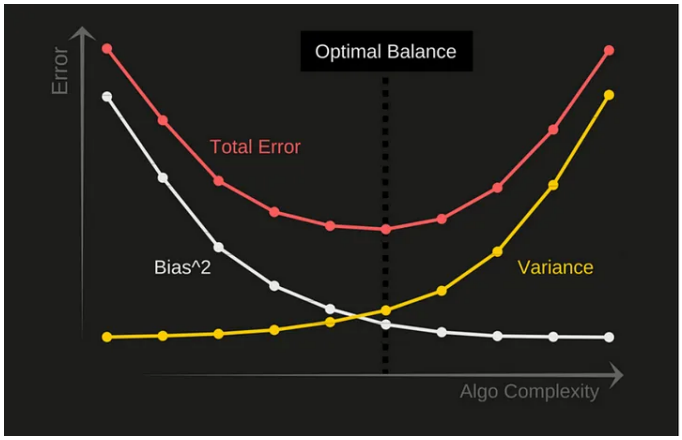


★ **Is there a learning method that is optimal for all text classification problems? → No!**
因为不同的问题的特点不同, 需要在**Bias**和**Variance**中做的**tradeoff**也不同. **The BEST way is to combine different methods!**

👉参考文献**1**(建议完整看完)**:** [WTF is the Bias-Variance Tradeoff? (Infographic)]
👉参考文献**2**(建议完整看完)**:** [Understanding the Bias-Variance Tradeoff]

# 9. Inverted indexing

## 9.1. 定义:

9.1.1. 维护一个dictionary, 其中key是term, value就是包含有这个term的所有docs.
9.1.2. 之所以叫Inverted index是用于区别forward index(即正常情况下普遍以docs作为key来统计不同单词在这个docs里出现的次数)

## 9.2. 特点: Terms in the inverted file index are refined

9.2.1. **Case folding**: converting all uppercase letters to lowercase (所有大写转小写)
9.2.2. **Stemming**: reducing words to their morphological roots (所有词态还原为词根)
9.2.3. **Stop words**: removing words that are so common they provide no information (把所有无意义词(I, you, me…以及语气词)都去掉)

## 9.3. 经典数据结构(用一个🌰展现)

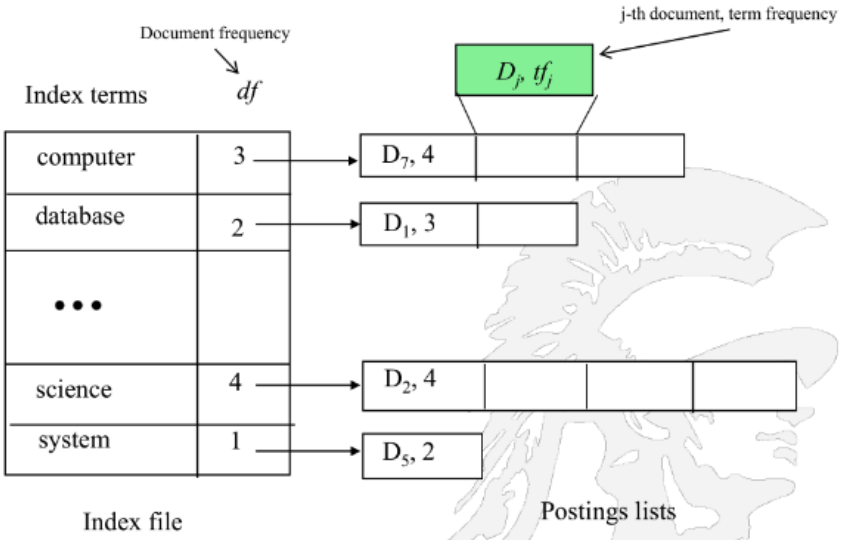


9.3.1. **Index file:** 把整个inverted index看作一个dictionary, 那么index file就是dictionary中的key, 但同时index file本身也是一个(key, value)的形式.

9.3.1.1. 每个**term**对应一个**IDF**(Inverse Document Frequency, 表示包含这个词的文档一共有多少个, 也就是当前这个**term**对应的**postings list**的长度)

9.3.1.2. Index file被保存在**memory**中, 用**pointers**指向**postings lists**

9.3.1.3. Index file的terms是按照**alphabetically**从小到大排序

9.3.2. **Postings lists:** 每个postings list是一个链表**(link-list)**, 每个元素存两个值, 一个存对应的**term**的**document ID,** 另一个是**TF(Term Frequency, 7.4.1.1)**

9.3.2.1. Posting lists被保存在**disk**中, 按照**document ID**从小到大排序

★ 一个不太一样的**Example:** 在这个🌰里只处理一个document, POS代表了term在文档中的位置, 可以看到这时的key就是term, 而value变成了对应的term在document中出现的位置的集合. 虽然看上去和上面讲的结构不太一样, 但本质上都是一个**dictionary,** 并且**postings lists**都可以用链表存储.

★ **Note:** 这里有个小问题就其实position和positions应该被认为是一个term, 同样的word和words也应该被认为是一个term

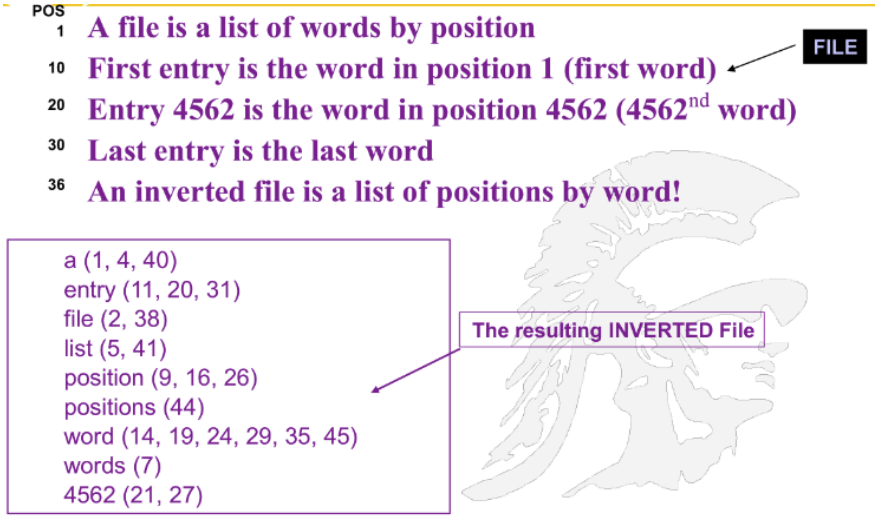


## 9.4. Inverted indexing处理一个query的流程

★ **Example:** 假设我的**query**是**which plays of Shakespeare contain the words Brutus AND Caesar but NOT Calpurnia (**注意这个**query**并不是真正我查询的输入**,** 只是一个逻辑表达而已**)**

### 9.4.1. Naive Solution:

9.4.1.1. 方法: 找出所有包含**Brutus**和**Caesar**的**Shakespeare plays**然后筛选掉那些有**Calpurnia**的

9.4.1.2. 问题: **too slow**; **needs large space**; **doesn't allow for other operations**即只能针对这一个query

### 9.4.2. Term-Document Incidence Matrix:

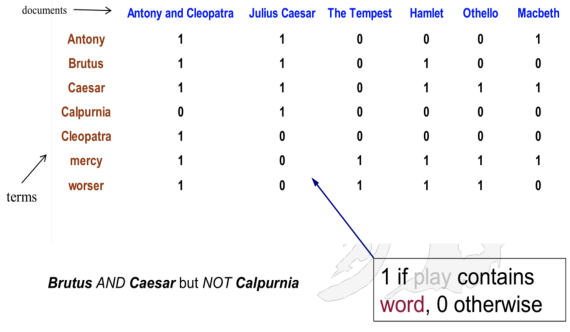


9.4.2.1. 方法: 维护一个01矩阵来表示哪些term在哪些document里出现过, 只需要根据逻辑关系进行相应的位运算即可得到最后结果(以上面的query为例, 位运算就是**110100 AND 110111 AND (NOT 010000) = 100100**, 即"Antony and Cleopatra"和"Hamlet"是符合要求的结果)

9.4.2.2. 问题: 虽然结果是正确的且可以覆盖其他query, 但是从上面的矩阵可以看出有很多为0的位, 这些**0**位占据了大量空间(即这个矩阵是**sparse matrix**)

### 9.4.3. Inverted index with Link-list(实际上就是9.3的模型):

9.4.3.1. 基本结构:

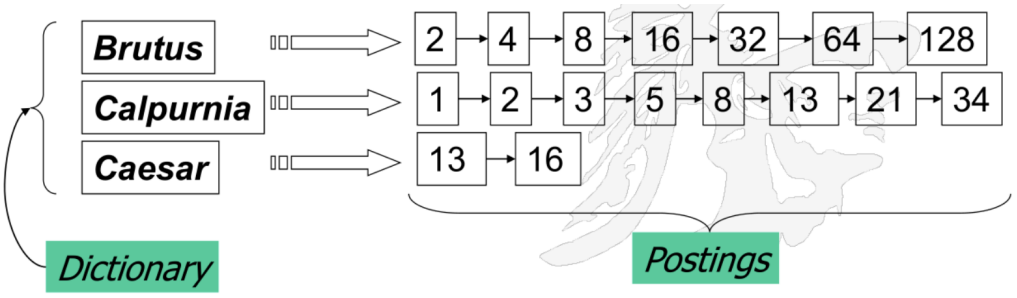


9.4.3.2. 第一步: **Extract words** (将每个doc的term都提取出来, 并且以**(term, doc ID)** 的方式存在一个表里. 这个时候不需要任何**merge,** 即哪怕一个**doc**里的**term** 出现了两次也分成两行来记录)

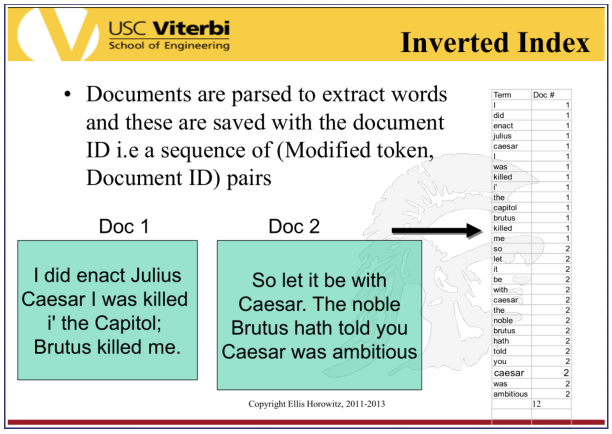


9.4.3.3. 第二步: **Sorted terms** (将所有terms按照 **alphabetically order**从小到大排序, 此时仍然不需要做任何的merge操作)

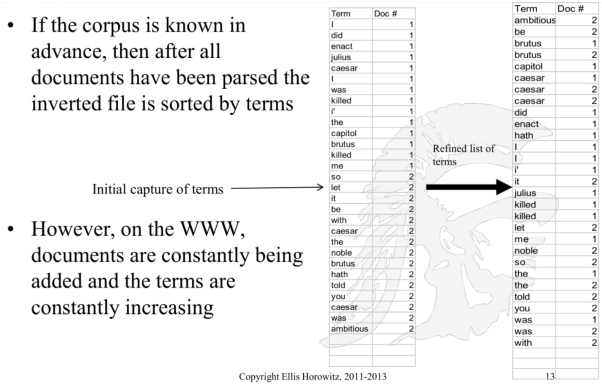


9.4.3.4. 第三步: **merge single document** (将同一个文档的同一个term进行merge, 在表格中增加一列来记录

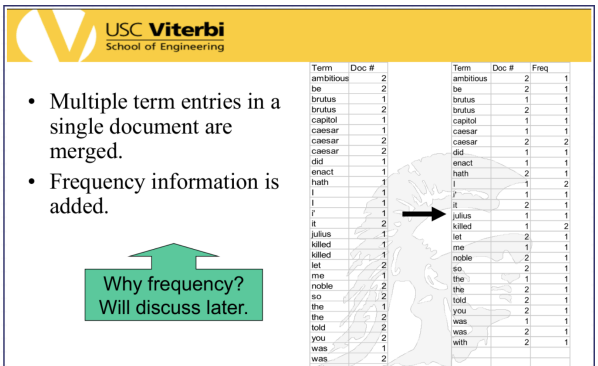

frequency)

9.4.3.5. 第四步: **merge multiple documents** (将terms进一步merge, 形成了最终的dictionary形式. 右图里左边的部分是index file, 右边的部分是postings lists. 这一步完成后就得到了9.4.3.1中的图)

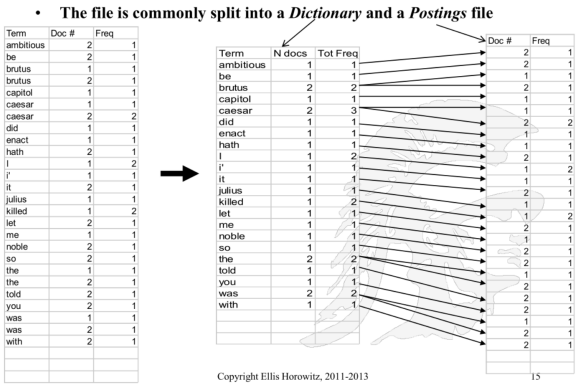


★ 为什么要用**Link-list**而不用**array**来维护呢? (即**array**和**link-list**的优缺点各是什么)

**g**

➢ **Array pros:**

➢.1. **randomly access to any element**

➢ **Array cons:**

➢.1. **fixed memory (<u>partially correct</u>, not fixed in JS);**

➢.2. **difficult to insert new or delete a middle element;**

➢.3. **Operating system has to find a block of memory all next to each other, if the memory is too fragmented, it's hard to find a continuous block of memory** (完整连续的空间)

➢ **Link-list pros:**

➢.1. **Easy insert or delete a middle element;**

➢.2. **Can distribute the data anywhere in the memory, just need pointers to point to each other (do not need a continuous block**完整连续)

➢ **Link-list cons:**

➢.1. **Can only follow the order to access elements** (如果使用循环链表 **circular linked list,** 可以从头或者从尾开始访问, 否则只能从头访问)

★ 该怎么改进**link-list**的不足呢? → **Skip Pointers!** (<u>但是注意即使用了**skip pointers, link-list**仍然做不到**randomly access**</u>)

9.4.4. **Skip Pointers**

9.4.4.1. 正常link-list得到最终结果: 三个link-list根据长度从小到大的顺序进行merge (比如在这里就是Caesar先和Brutus合并, 合并出的list再和Calpurnia合并得到最后的结果). 目的是找到相同的 每次merge的复杂度是**O(m+n)** (m, n分别是两个list的长度

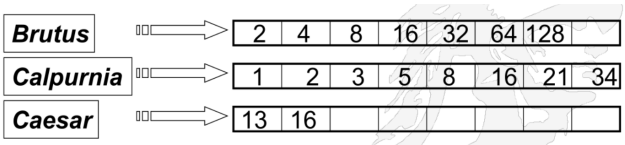


Query: ***Brutus*** *AND* ***Calpurnia*** *AND* ***Caesar***

★ 为什么要按长度从小到大排序**?** → 节省平均运算次数 (比如这里如果Brutus先和Calpurnia合并, 得到的list是[2,8,16], 然后再和Caesar合并, 总运算次数=7+8+3+2=15+5=**20**; 如果Brutus先和Caesar合并, 得到的list是[16], 然后再和Calpurnia合并, 总运算次数=7+2+1+8=9+9=**18**)

★ 为什么需要**Skip Pointers?** → 以上图为例, 假设我们正在合并Brutus和Calpurnia, 并且我们已经对比到16, 16了. 此时Brutus的下一个是32, 我们需要在Calpurnia里一个一个访问16后面的元素看有没有32. 但是如果我们能模拟出类似array的特点, 即可以跳着访问元素, 就可以把明显不可能存在32的区间跳过以节省时间了.

9.4.4.2. Skip Pointers结构: 将整个link-list均分成若干部分, 新建pointers连接这些部分 (相当于一条快速通道, 可以想象高速上的express)

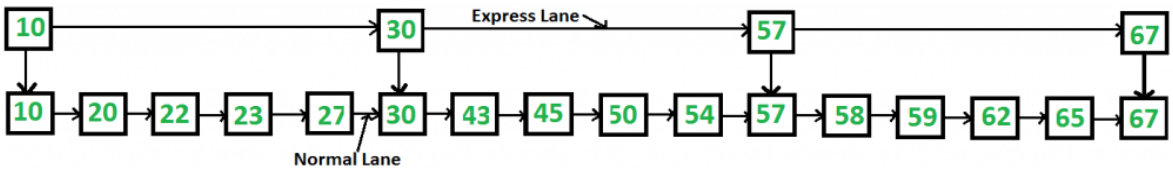


★ 怎么均分最高效**?** → 尽可能将整个**link-list**分成$\sqrt{n}$份**,** 额外用**O(**$\sqrt{n}$**)**空间

9.4.4.3. Skip Pointers查询复杂度: **O(**$\sqrt{n}$**)**, 其中n为link-list长度

~~扩展**(不会考):** 这是只添加一条express lane的复杂度, 事实上我们可以添加logn条express lane, 最下面一层是每两个elements连一个, 往上一层是每四个elements连一个, 再往上是8, 16, 32... 可以想像此时我们其实构建出了一个三叉树结构, 因此简单可以证明搜索某一个元素的复杂度为**O(logn)**~~

★ **Example:** 假设我们下一个处理的是上面的32, 下面我们正在8的位置. 我们可以从8处的skip pointer看到8对应的是31, 而31比32小, 且这里有序. 所以我们可以直接跳过17->21->31这个部分

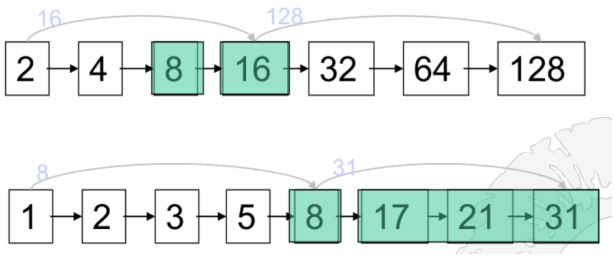


## 9.5. Phrase Queries

9.5.1. 问题: 有时候我们会把**query**作为一个**phrase**去查询, 我们不希望它是按照term拆开来分别对应的, 因为有时候phrase有特别的意义 (例如stanford university)

9.5.2. **Solution1: N-grams** (其实也就是N-shingle). 这里介绍Biword (2-gram): 将两个连续的words作为一个dictionary term

9.5.2.1. Biwords will cause an explosion in the vocabulary database (很好理解)

9.5.2.2. Queries longer than 2 words will have to be broken into biword segments

★ **Example:** Query: "stanford university palo alto" 对应的Biwords就是{stanford university, university palo, palo alto}

9.5.2.3. 会造成很多false positive (很多结果会包含biwords但是不包含完整的query)

9.5.2.4. **N-grams**遵循**Zipf distribution** (即随着n的增大渐渐地很多n-word-term的frequency都会特别低)

★ 💥课后思考**(**可能会考**):** 下图是真正的term长度和在网络中的出现频率的曲线, 可以发现它和我们上面描述的Zipf其实有所不同, 为什么**?** → 搜不到答案**,** 个人认为和语言学相关**,** 例如搜索**ceramics comes from,** 或者**serve as the inspiration.** 也可能是**term**太短不能准确描述用户的搜索需求**,** 而用户通常又不想完整打完一句话**,** 而是用一个短语或者几个**noun**形容自己的**query**

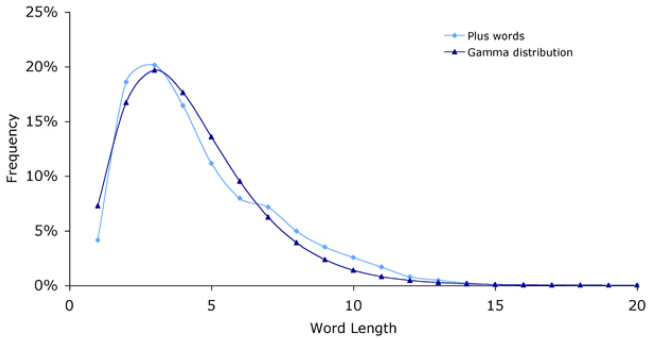

9.5.3. **Solution2: Positional Indexes(9.3的🌰里有所展示)**: 每个term在对应的doc ID之后还多存一个位置信息, 表示这个term在这个doc里的哪些位置出现了.

★ **Example:** 假设我们搜了"to be". 这里比如to的"2:1,17…"表示的就是在2这个doc里第1个词, 第17个词... 是to. 所以如果我们看to和be都在一个文档出现并且有存在**positional index**相邻的情况就说明这个文档里出现了我们要的phrase

- ***to:***
  - ***2*:1,17,74,222,551; *4*:8,16,190,429,433; *7*:13,23,191; ...**
- ***be:***
  - ***1*:17,19; *4*:17,191,291,430,434; *5*:14,19,101; ...**

9.5.4. **Solution3: Biword +** part-of-speech-tagging (词性分析): 先用词性分析得到query中所有单词的词性, 只考虑nouns进行biwords的构建再回到solution1 (基于假说"nouns and noun phrase经常出现且最能概括用户的意思")

★ **Example:** 假设query是 "renegotiation of the constitution", 经过词性分析后的到的是 **N X X N** (X代表preposition, N代表noun). 因此我们就得到了**biword "renegotiation constitution"**

★ **Note**: part-of-speech-tagging的程序可以通过statistical或者rule-based的方法训练出来

## ~~9.6. Distributed Indexing: 用MapReduce~~ (之后会讲的)

## 9.7. Dynamic indexing

9.7.1. 问题: 之前讨论的inverted index都是在数据不变的情况下, 但是现实生活中应用的时候数据可能随时都在变化, 需要维护一个动态的index

9.7.2. 方法: 维护一个大的**main index**和一个小的**auxiliary index.**

9.7.2.1. 定义: main index相当于主数据库, auxiliary index相当于一个小型数据库, 存在memory中.

9.7.2.2. 查询过程: 在一段时间内, 新的docs会先存在auxiliary index里. 这时用户给一个query, 我们会在**main index**和**auxiliary index**中都去查询**,** 会得到两个**link-list**, 对这两个**link-list**再**merge**一次就得到了最终给用户的结果.

9.7.2.3. 每过一个时间段**,** 我们把**auxiliary index**里的内容都转移到**main index**

★ 💥课后思考**(**可能会考**):** 如何动态删除某个**doc?** → 我们把要删除的**doc ID**都和在一起维护成一个**bit-vector,** 在**9.7.2.2**里得到最终结果后和这个**vector**在进行一次**merge**来**filter**那些删除后的文档 (Deletions are stored in an invalidation bit vector. We can then filter out deleted documents before returning the search result. Documents are updated by deleting and re-inserting them.)

➢ 扩展**: KNN with Inverted Index**(利用inverted index给KNN加速)**:** 得到一个query后, 首先用**Inverted indexing**得到一些**candidate docs**, 然后把query当成一个test document, 而candidate docs就是train documents. 由此跑**KNN**就能快速得到接近**query**想要得到的**docs**顺序**.** Testing Time: $O(B|V_t|)$, 其中B是一个test-document words在training documents中出现的平均次数, $V_t$ 是test document的vocabulary. 通常情况下B<<文档总数

# 10. Video Search Engines

## 10.1. How to index a video into database? → Metadata

10.1.1. Author, title, creation date, duration, coding quality, tags, description

10.1.2. Other aspects of video recognition are subtitles and transcription

## 10.2. How to rank a video (or sort videos)?

10.2.1. Relevance: using metadata and user preferences

10.2.2. Ordered by date of upload

10.2.3. Ordered by number of views

10.2.4. Ordered by duration

10.2.5. Ordered by user rating

★ **Note:** 用户可以选择sort by which, 如果没有选择则会对每个因素添加一个weight, 最后算出一个final ranking (不知道具体的公式)

## 10.3. YouTube Recommendation System (即YouTube如何推荐更多video给用户)

10.3.1. **Association Rule Mining**: 每一对视频 $(v_i, v_j)$, relatedness公式: $r(v_i, v_j) = \frac{c_{i,j}}{f(v_i, v_j)}$, 其中$c_{i,j}$表示视频i和j被co-watched的次数, $c_i$表示视频i被观看的次数, $c_j$表示视频j被观看的次数, $f(v_i, v_j)$是一个normalization function (e.g. $f(v_i, v_j) = c_i * c_j$ )

10.3.2. 当用户观看了一个视频**i, system**就会通过**10.3.1**中的公式计算出所有其他视频和**i**之间的**relatedness,** 并且从大到小排序**,** 最后选择**topk**推荐给用户

## 10.4. Two Technology Challenges for YouTube

10.4.1. **How to identify billions of videos?** → YouTube用固定长度11位的string来作为video ID (一共可以identify **(26+26+10)$^{11}$**个视频), 得到一个新的视频之后, 系统会随机给它分配一个**11**位的**string**作为**video ID**, 之后系统会搜索这个ID在database里存不

存在, 如果存在就重新随机给一个11位的string, 直到ID不存在重复. 把ID添加到video对应的URL尾部 (e.g. https://www.youtube.com/watch?v=**gocwRvLhDf8**)

10.4.1.1. **How to efficiently deliver the video to the desktop/mobile device? → CDN (Content Delivery/Distribution Networks).** 简单来说就是网络会解析用户的IP并且根据用户的IP地址分配一个最近的服务器来读取用户需要的资源 (比如你在北京看一个youtube上的视频, youtube就会找到一个离北京最近的服务器, 通过这个服务器把视频加载到你的网页上)

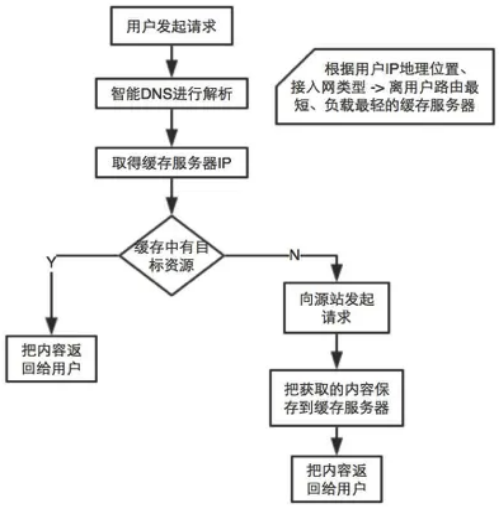


## 10.5. YouTube如何判断video duplication (即如何维护copyright)? → ContentID

10.5.1. ContentID: a **fingerprint** database of copyrighted content. 每个视频都会被YouTube将内容(音频, 画面)取样(sampling)之后处理成一个**spectrogram**. 然后spectrogram会被hash. 之后上传的视频也会得到一个hash value, 如果这个hash value和database中的某个hash value很接近, 那就是侵犯了著作权

★ **Note:** 这里的**hash function**会使用**SimHash(5.5),** 也就是内容越接近的视频得到的**hash**值最接近

- [x] **02/14/2023**课堂扩展内容**: Amplifies Scam**
- [x] 大致可以理解为网上存在很多错误的信息或者不实的信息但是很难分辨真伪. Saty用以表达对ChatGPT深深的担忧
- [x] 🌰: Google版ChatGPT: Bard, 在demo演示的时候被发现回答的内容出现了fact wrong(下图), 在回答问题「关于詹姆斯韦伯太空望远镜(JWST)有哪些新发现, 我可以告诉我 9 岁孩子哪些内容？」Bard 提供了三个要点, 其中一个指出「该望远镜拍摄了太阳系外行星的第一张照片。」
- [x] 然而, 推特上的一些天文学家指出这是不正确的, 第一张系外行星图像是在2004年不是用韦伯望远镜拍摄的.
- [x] 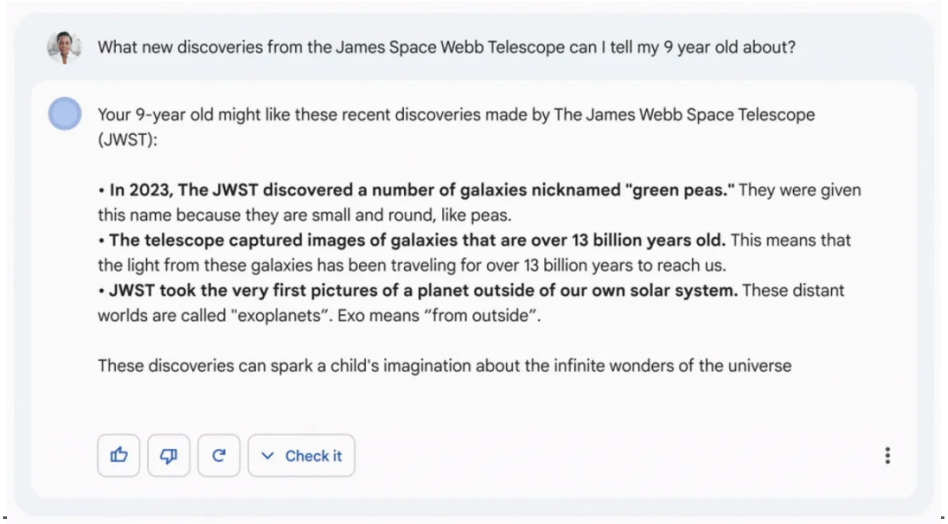

- [x] 个人理解: 如果了解ChatGPT本质其实很好理解这种错误. 因为它们本质上是自动生成系统.当前的AI不是查询已证实事实的数据库来回答问题, 而是接受大量文本语料库的训练并分析模式, 以推定任何给定句子中的下一个单词出现的概率. 换句话说ChatGPT在guessing问题的答案而不是searching

# 11. Query formulation

**11.1.** 问题**:** 传统的搜索无法处理需要筛选条件的**query (**🌰**:** 搜索**Apple AND orchard NOT computer**是想要得到不包含**computer**的结果**,** 但是搜索引擎无法判断**and**和**not**是**query**的一部分还是判断条件**)**

**11.2.** **Google**用符号表达式表示筛选信息**:**

11.2.1. Default (什么都不加): 表示**AND**表达式 (e.g. Apple orchard = Apple **AND** orchard)

11.2.2. **Quotes (“”**引号): 表达**exact phrase** (e.g. “Apple orchard”只会显示完整包含Apple orchard这个短语的结果)

11.2.3. **NOT (-**减号): 表达不要 (e.g. Apple -computer就不会返回computer相关的apple产品)

11.2.4. **Square bracket ([]**中括号):

11.2.4.1. 表达自动匹配相似单词 (e.g. [child bicycle]会得到包含“child”, “children”, “children’s”, “bicycles”, “bicycling”等结果)

11.2.4.2. 表达不要匹配**stop word** (e.g. [the who]就不会把the和who当作stop word二是搜索the who的结果)

11.2.5. **OR** (或): A or B表达返回匹配A的结果或者匹配B的结果 (e.g. Apple OR Pen会得到和Apple有关的结果, 也会得到和Pen有关的结果, 但不会得到Apple Pen的结果)

11.2.6. **Connect (+**加号**) and Anyword (***星号**)**: (e.g. it’s +a * world中会将+后的a当作正常单词而不是stop word 被删掉, 而*会返回任何符合a “somewords” world的结果)

11.2.7. **filetype:** 表示只搜索后缀为某一类文件的结果 (e.g. filetype:**pdf** apple就只会返回apple结果中的pdf文件)

11.2.8. **inanchor:** 返回的是包含anchor text指向的网页 (e.g. restaurants inanchor:gourmet返回的是网页中含有restaurants并且被一些anchor text中含有gourmet的网页指向的网页 (anchor text就是链接上的文字, 比如GOOGLE))

11.2.9. **intext:** 返回必须要网页里的文字包含query的网页 (e.g. 搜索youtube.com不会返回link里包含youtube.com的网页, 而是返回网页里body text有youtube.com的网页)

11.2.10. **intitle:** 只返回网页标题里包含搜索query的网页

11.2.11. **inurl:** 只返回url里包含query的网页

11.2.12. **site:** 只返回某些域名里的网站 (e.g. site:usc.com就只会返回usc.com里的网页)

11.2.13. **info:** 只返回google关于搜索query的信息 (e.g. 搜索info:applepie就会先返回recipe)

11.2.14. 其他特殊符号(e.g. @表示social network; $表示price)

## 11.3. Google其他的query rules

11.3.1. Query的上限长度只有32个words

11.3.2. 会优先返回query中words位置最接近的结果 (e.g. snake grass返回的是plants; snake in the grass返回的是sneaky people) (不会中间插词)

11.3.3. 会优先返回query中words顺序不变的结果(e.g. Apple watch返回的是苹果手表而不是watch apple)

11.3.4. 搜索不管大小写 (e.g. NEWS和news是一个结果)

11.3.5. 会自动忽略一些符号 (e.g. ! ? .)

## 11.4. Relevance Feedback & Query Expansion

11.4.1. Relevance Feedback: 用户搜索了query之后Google还会推荐给他们相似的query点击 (相关搜索)

11.4.2. Auto-Completion: 用户一边输入Google会一边帮用户补全他们可能想输入的query

★ **Note:** 这里的用的数据结构是字典树, 自动补全的query排序的顺序是根据之前大数据的搜索次数决定的 (搜索越多的越先被推荐)

11.4.3. Spelling Correction: 会在用户输入query后识别拼写错误并推断出用户最可能想搜索的query

# 12. MapReduce

## 12.1. 背景(为什么我们需要MapReduce & MapReduce做了什么):

12.1.1. 需要处理数量非常庞大的数据, 如果只用一台机器耗费的时间太久了 (e.g. Google每天可能要处理几十亿的搜索, 如果只有一台机器有的人等一辈子也等不到结果)

12.1.2. MapReduce相当于把一个很大的任务分成很多小份, 每一份交给一台机器完成, 这一部分叫做***Map***. 在所有机器得到结果之后它们的结果会汇总到另外一些机器进行合并, 这一部分叫做***Reduce***

## 12.2. 以一个统计单词的例子来展现整个MapReduce的过程

12.2.1. 任务: 现在有三段话, 我需要统计这段话里每个不同的单词及它出现的次数

12.2.2. 传统方式: 一个人从头到尾记录每个单词及它的出现次数

12.2.3. Map: 把三段话分成三份, 交由三个人来负责, 每个人负责处理其中的一段话. 每个人的任务是将每个单词及它在该段落出现的次数封装成(A, #of A)的形式.

12.2.4. Shuffle(Group): 得到三个人分别统计之后的结果, 对它们的Key也就是(A, #of A)中的A进行hash, 根据hash的值决定将这个tuple分给哪个Reducer.

12.2.5. Reduce: 在Map之后每个人都会得到很多单词记录, 但是三段话里可能有些单词是重复出现的, 我需要最终得到合并以后的结果. 因此, 我又找了两个人帮我统计. Shuffle会决定将哪些tuple分给第一个人, 哪些tuple分给第二个人. 这两个人就根据tuple中的Key把它们对应的Value也就是#of A进行相加就得到了最终的结果.

★ **Note: MapReduce**的加速倍数符合**Amdahl's law** **(**即并行的机器数和提升速度成近似线性相关**.** e.g.用原来三倍的机器跑就可以比原来快接近三倍**)**

## 12.3. Map

12.3.1. Mapper负责"分", 即把复杂的任务分解为若干个"简单的任务"来处理. "简单的任务"包含三层含义:

12.3.1.1. 数据或计算的规模相对原任务要大大缩小

12.3.1.2. 就近计算原则, 即任务会分配到存放着所需数据的节点上进行计算

12.3.1.3. 这些小任务可以并行计算, 彼此间几乎没有依赖关系 **(**不需要其他**map**的结果来完成自己的**map**工作**)**

## 12.4. Reduce

12.4.1. Reducer负责“合”, 即把所有Mapper得到的中间结果根据任务的不同需要合并成最终用户想看到的格式 (比如在12.2的🌰里reducer的主要工作就是对同一个单词在三个段落里出现的次数进行累加)

## 12.5. Shuffle

12.5.1. Shuffle负责对中间结果进行排序并且分发给对应的Reducer

★ 为什么要排序? → 因为要**group**, 排序(key一样的放在一起 and order) 以后从头开始看, 什么时候key跟上一个key不一样了什么时候就应该是新的group了

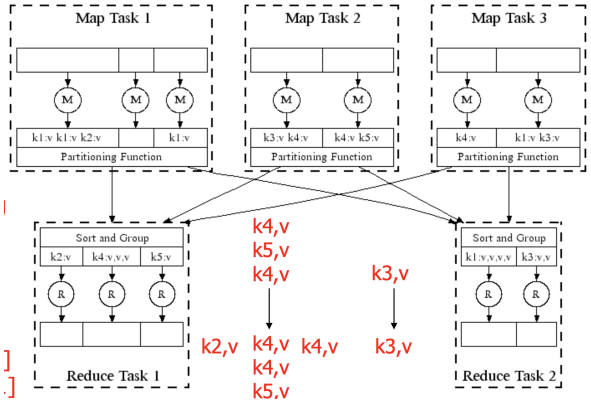


12.5.2. Shuffle过程(下图): 这里的sort&merge用的是外部排序.

12.5.2.1. 首先Maps会各自得到一些(key,value)的对, 然后根据**hash**分别将不同的key分开成不同的partitions各自排序. 比如在Map Task2中这一步的结果应该是{(k4,v), (k4,v), (k5,v)}, {(k3,v)}, 因为k4和k5是要给Reduce Task1的, 而k3是要给Reduce Task2的

12.5.2.2. 之后Reduce Task会收到来自不同Map Task的包裹, 包裹内各自是排好序的, 因此Reduce Task只需要执行外部排序的merge部分就可以最终排好序的group了

Keys in the same partition are sorted (keys from different partitions may not be)

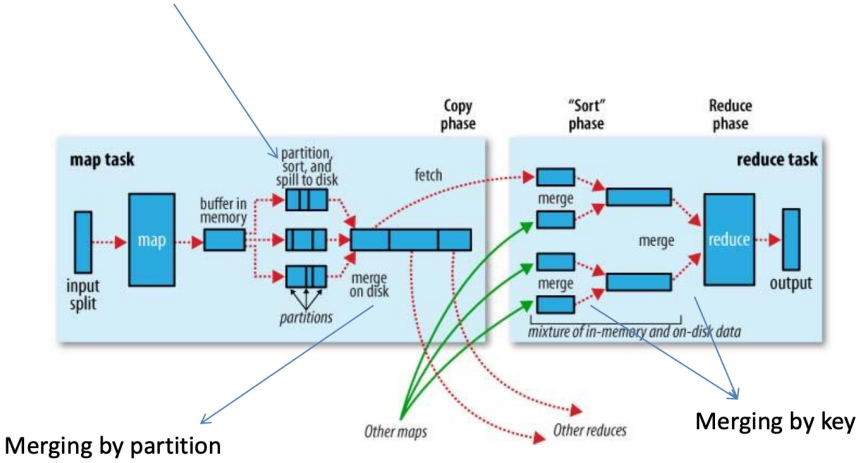

## 12.6. Combiner (Optional)

12.6.1. 可以理解为Map Tasks处理完各自的任务之后先进行一个中间操作, 再给Reducer Tasks; 这么做可以减小数据传输从而加快整体速度(但不是什么情况都可以用combiner的,比如求平均就不可以)

12.6.2. 以统计单词个数为例:假设有两个Map Tasks和一个Reduce Task。其中:

12.6.2.1. *Mapper 1*

input: : [ (0, “here”), (5, “here and there”) ]

**output: [ (“here”, 1), (“here”, 1), (“and”, 1), (“there”, 1) ]**

12.6.2.2. *Mapper 2*

input: : [ (0, “here or there”), (14, “there”) ]

**output: [ (“here”, 1), (“or”, 1), (“there”, 1), (“there”, 1) ]**

12.6.2.3. 经过**combiner**的处理以后:

*Combiner 1:* **[ (“here”, 2), (“and”, 1), (“there”, 1) ]**

*Combiner 2:* **[ (“here”, 1), (“or”, 1), (“there”, 2) ]**

12.6.2.4. 可以看出来这里**combiners**先统计了各自的答案, 再给**Reducer**

12.6.2.5. 最后**Reducer**整理出的结果:**[ (“here”, 3), (“and”, 1), (“or”, 1), (“there”, 3) ]**

## 12.7. MapReduce过程图解 (One more example)

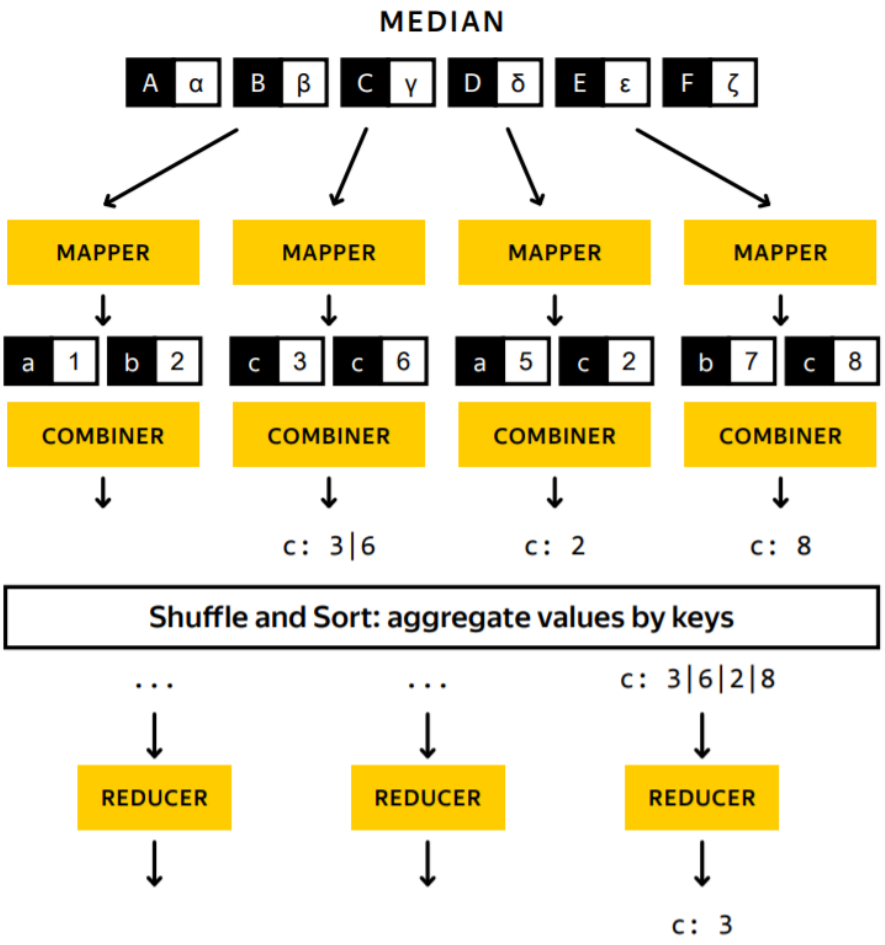


★ **Note:** 在整个Web Search Engine中用户**Search**的过程和Engine内部**Create Inverted index**的过程都需要**MapReduce (**每个**block**包含一部分**documents)**

## 12.8. Distributed Execution Overview

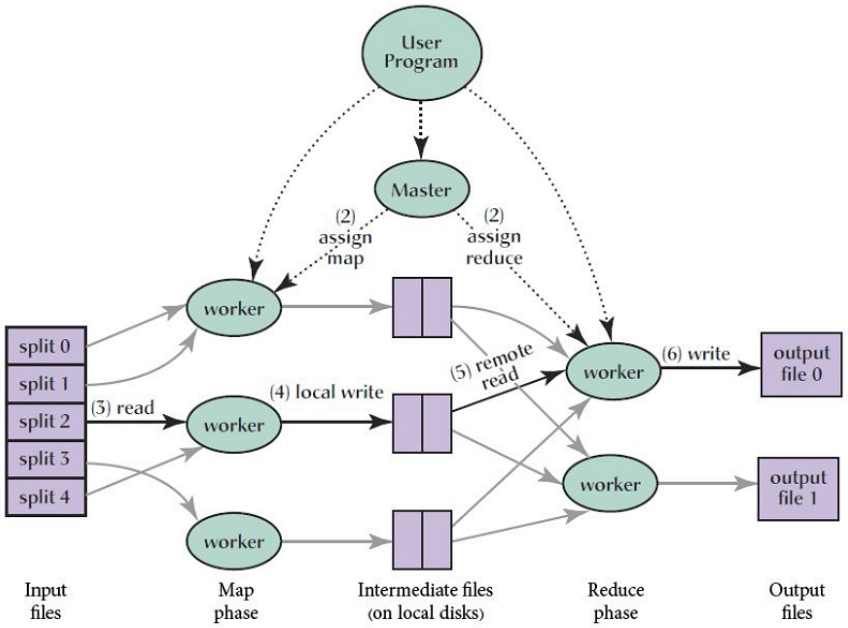


12.8.1. MapReduce之上的宏观概念, 如何分配机器来进行Map和Reduce

12.8.2. **Master Node**:

12.8.2.1. 一个Master可以控制若干个worker

12.8.2.2. Master可以分配给worker一个map任务或者一个reduce任务

12.8.2.3. Master要随时追踪每个worker的状态**(idle, executing, completed, crashed)**

12.8.2.4. **Master**知道所有**map**任务产生的文件的位置和大小**,** 并且会把这些信息告诉对应的**reducer**

## 12.9. MapReduce应对Failure (Fault Tolerance)

12.9.1. 如果是一个Task crashed了:

12.9.1.1. 在另一个node上重新尝试这个task

- 对Map任务是可行的因为Map是MapReduce的第一步, 没有需要读入的东西
- 对Reduce任务是可行的因为Reduce需要的是Map的输出, 而**Map**的输出是存在**disk**里的

12.9.1.2. 如果一个task在换过多次node之后还是fail了, 忽略这个chunk

12.9.2. 如果一个Node crashed了:

12.9.2.1. 把当前分配给这个node的所有tasks分配给其他nodes

12.9.2.2. 把之前在这个node上跑完的所有Map任务在其他nodes上重新跑一遍 (因为**Map**跑完的结果都会存在**node**上**,** 如果**node**挂了那这些输出也都丢失了)

12.9.3. 如果一个task跑的非常慢:

12.9.3.1. 把这个task的一个copy放在另一个node同时跑

12.9.3.2. 哪一个node先跑完就取那一个node的结果, 并且kill掉还没跑完的那个

12.9.4. 如果一个**Map worker node crashed**了:

12.9.4.1. 会被Master发现并且所有被分配给这个**worker**的**map**任务都要重新分配给其他**map worker**重新做一遍

12.9.4.2. Master会把分配给这个**worker**的**map**任务的状态都设置成**idle**, 当某个worker的状态成为available了就分配map任务给它

12.9.4.3. Master会将新的**map**结果的地址位置发给Reduce worker

12.9.5. 如果一个**Reduce worker node crashed**了:

12.9.5.1. Master会把分配给这个**worker**的**reduce**任务的状态都设置成**idle**, 当某个worker的状态成为available了就分配reduce任务给它

## 12.10. GFS (Google File System)

12.10.1. 问题: Google要存的东西实在是太多了, 即使用了MapReduce, Master node也存不下map worker生成的结果

12.10.2. Solution: 再加一层**chunk node (chunk server => team leader (a little master))**

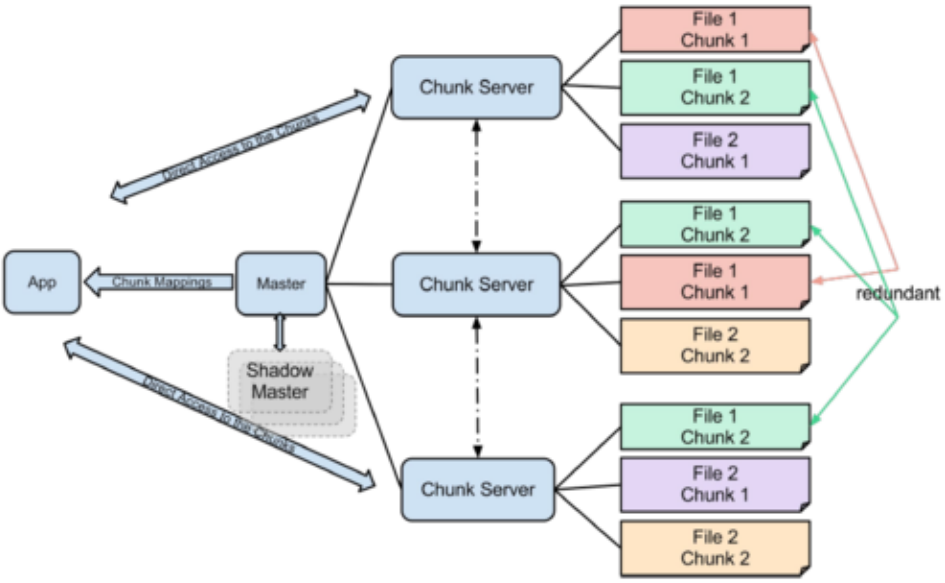


## 12.11. BigTable

12.11.1. BigTable 是一种压缩的, 高性能的, 高可扩展性的, 基于GFS的数据存储系统, 用于存储大规模结构化数据, 适用于云端计算. BigTable中的**row**存储方式是**(key, value)**

12.11.2. BigTable中的每一个table具有的特点:

12.11.2.1. Sparse

12.11.2.2. Distributed

12.11.2.3. Persistent

12.11.2.4. **Multidimensional (various time and versions)**

12.11.2.5. Sorted map

12.11.3. BigTable中的要素:

12.11.3.1. Row key: 即行关键字, 存的是比如学生id之类的. 是排好序的, 排序方式可以自定义

12.11.3.2. Column Family: 把一些相关的列整合成一个family. BigTable也可以根据**column**检索 (比如一列存的是学生的GPA, 就可以直接把这一列取出来求平均而不需要一行一行访问)

12.11.3.3. Cell: 表格里的每一个数据被称为一个Cell

12.11.3.4. Timestamp: 这里体现了12.11.2.4中的BigTable的**Multidimensional**的特点. 通常我们存的表格都是二维的, 但是在BigTable中还可以存同一个**cell**在不同时间的数据 (比如一个学生在不同学期的GPA)

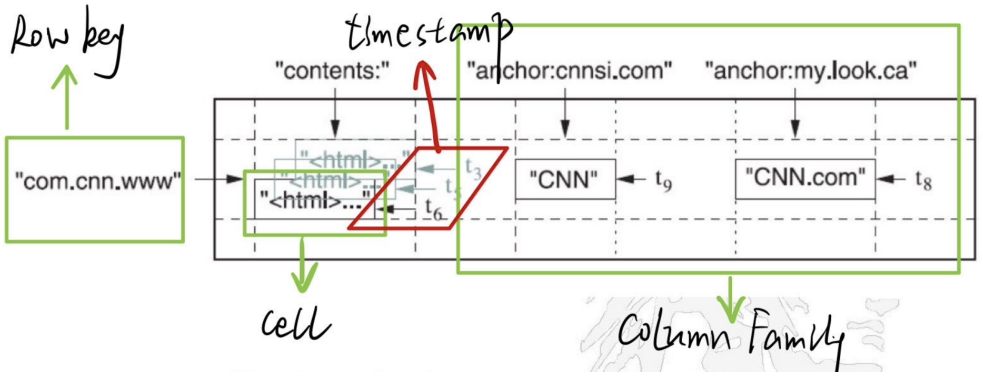


# 13. Knowledge graphs

## 13.1. Taxonomy

13.1.1. 定义: A **classification** or **categorization** of a complex system

13.1.2. 特点:

13.1.2.1. 通常以**tree**的结构呈现 (e.g. CS下面有不同的major, 每个major又有自己的不同topic)

13.1.2.2. 遵循**Inheritance**, 即可以把Taxonomy理解成父类与子类之间的继承关系 (特点是这里的父类的所有**property**都是**public**的而没有**private**的, 即子类会继承父类的所有**property**)

13.1.2.3. 主要应用于knowledge management, information retrieve等领域

## 13.2. Ontology

13.2.1. 定义: A set of concepts and categories in a subject area or domain that shows their **properties** and the **relations** between them.

13.2.2. 特点:

13.2.2.1. 突出的是entity之间的**relationship** (e.g. 同义关系、相反关系、包含关系), 目的在于给AI提供一种人类知识的表示方式

13.2.2.2. 通常以**directed**, **labeled**, **cyclic graph**的结构呈现

13.2.2.3. 主要应用于AI领域

## 13.3. Knowledgebase

13.3.1. 定义: 一种用于store和retrieve在Ontology的数据和关系的计算机系统

13.3.2. 特点:

13.3.2.1. Representing: 能够表达在ontology中每个的entity的**property**及**information**

13.3.2.2. Reasoning: 能分析ontology中不同的entity之间的**relationship**

13.3.3. Knowledge-based system: 一般用于搜索引擎的AI, 由两个elements组成:

13.3.3.1. Knowledgebase: 能存储和表达某个entity的信息

13.3.3.2. **Inference engine**: 能通过某些逻辑推导出entity之间可能存在的关系 (e.g. 西雅图经常下雨 → 防滑轮胎在西雅图的销量比普通轮胎更高; 用户搜索毕加索, 推荐给用户毕加索的画作)

## 13.4. RDF Data Model

13.4.1. 将entity之间的关系描述成**<subject><predicate><object>**的形式(e.g. <Bob><is a><person>)

★ **Note:** 在回答一个问题的时候knowledgebase会综合多种信息来源总结出答案

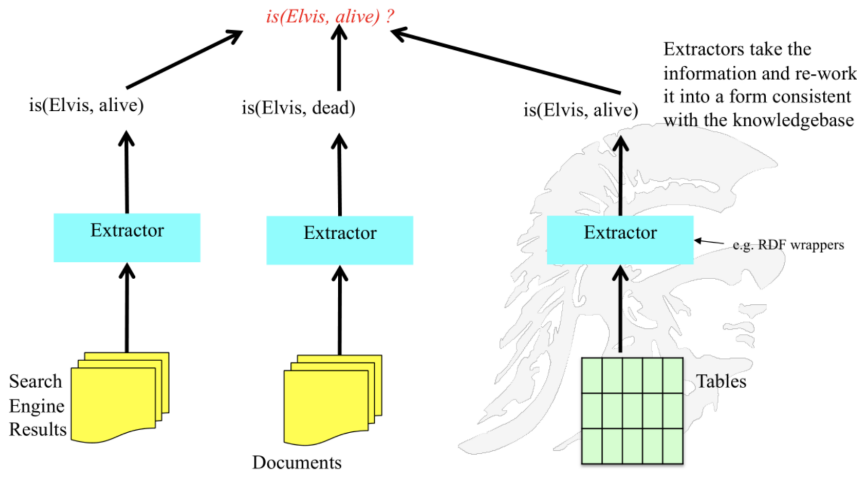

### 13.5. 如果有多个**Ontology**, 一个**Knowledgebase**该如何将它们整合在一起呢? → 寻找不同的**Ontology**之间等价的**Entity**

13.5.1. 🌰: 同一种病在全球不同国家不同地区可能有很多不同的叫法, 并且有各自的治疗方法, 它们构成了很多不同的Ontology. 这些病的不同名字就构成了等价的**Entity**, 连接这些等价Entity就能把所有治疗这个病的方法整合进一个knowledgebase.

★ 如何判断哪些Entity是等价的呢? → 通过它们共有的property计算相似性

### 13.6. Inference engine

13.6.1. 定义: Applies logical rules to a knowledgebase to deduce new information

13.6.2. 两种模式: **Forward chaining**, **Backward chaining**

13.6.3. **Forward chaining**: 通过现有的facts推测出新的**facts (**即当前**knowledgebase**不存在的**facts)**

13.6.3.1. 表示形式: **"P implies Q"**和 **"P"**都是**true,** 那么**Q=true**

13.6.3.2. 🌰: "If today is Tuesday, I have a class", "Today is Tuesday" → "I have a class"

13.6.3.3. 搜索引擎绝大多数时候使用forward chaining

13.6.4. **Backward chaining**: 给定一个目标, 推测出要让这个目标发生需要有的facts (要比**forward chaining**困难. E.g. 考试, 给定一个需要达成的目标, 求需要哪些技术和facts实现这个目标)

★ **Note: Cuckoo Hashing** (Tiktok用于高速缓存和查找的算法). 它通过两个不同的哈希函数来避免哈希冲突, 并通过迭代方式来解决任何冲突. 基本思想是将一个键值对映射到两个哈希表位置中的一个, 如果其中一个位置已经被占用, 则将该键值对放置在另一个位置, 如果另一个位置也被占用, 则将原位置上的键值对移到它的另一个位置, 依此类推, 直到所有键值对都能够被插入到哈希表中. 如果无法插入, 则需要重新哈希或扩展哈希表大小, 以容纳更多的键值对. Cuckoo hashing的优点是平均插入和查找的时间复杂度为**O(1)**, 而且不需要解决链式哈希表中可能出现的长链问题. 但是, Cuckoo hashing的缺点是需要占用两倍的内存空间, 而且对于某些哈希函数和数据集, 可能会出现插入失败的情况, 需要进行重哈希或扩展哈希表大小.

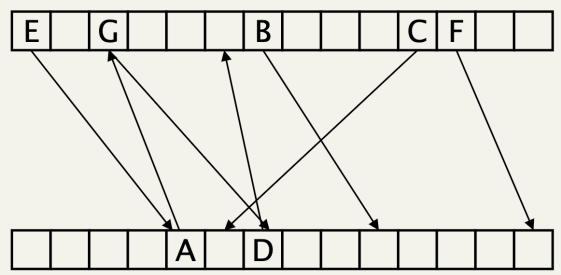

# 14. PageRank

## 14.1. PageRank基础知识

14.1.1. **Random Surfer Model**: 从网络中随机一个**page**开始, 随机选择一个link点进去。一个页面被点击到的次数越多它就越重要

14.1.2. 特点:

14.1.2.1. 本质上是一个**vote**模型, 通过其他pages的投票表示自己的重要性

14.1.2.2. 只关心link, 不关心**page**内容. 只有in-link能给page带来重要性

14.1.2.3. 可以看作一个**probability distribution**, 用于形容一个人随机点**link**能到某个**page**的概率

## 14.2. Simplified PageRank algorithm

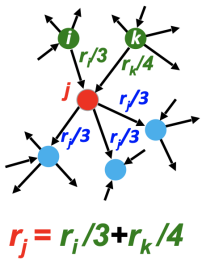


14.2.1. If page j with importance $r_j$ has N out-links, each link gets $\frac{r_j}{N}$ votes (把自己的重要性分成N份给自己的目标)

14.2.2. Page j's own importance is the **sum of the votes on its in-links**

14.2.3. 可以描述为$r_j = \sum_{i \to j} \frac{r_i}{d_i}$, 其中$d_i$表示点i的**out-degree**

14.2.4. 流程:

14.2.4.1. 初始化page的rank为$\frac{1}{n}$, 其中n为page总数

14.2.4.2. 对每个点按照**14.2.3**的公式计算新的rank值.

14.2.4.3. 重复14.2.4.2直到网络拟合 (前后两个iteration每个page的rank都没什么变化)

★ **Example:**

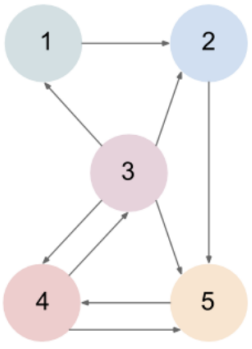


| | Iteration 0 | Iteration 1 |
|---|---|---|
| $P_1$ | 1/5 | 1/20 |
| $P_2$ | 1/5 | 5/20 |
| $P_3$ | 1/5 | 1/10 |
| $P_4$ | 1/5 | 5/20 |
| $P_5$ | 1/5 | 7/20 |

1. Iteration 0: Initialize all pages to have rank ⅕.
2. Iteration 1:
3. **$P_1$:** has 1 link from $P_3$, and $P_3$ has 4 outbound links, so we take the rank of $P_3$ from iteration 0 and divide it by 4, which results in rank (⅕)/4 = 1/20 for P1

**$PR(P_1) = (\frac{1}{5})/4 = 1/20$**

4. **$P_2$:** has 2 links from $P_1$ and $P_3$, $P_1$ has 1 outbound link and $P_3$ has 4 outbound links, so we take (the rank of $P_1$ from iteration 0 and divide it by 1) and add that to (the rank of $P_3$ from iteration 0 and divided that by 4) to get ⅕ + 1/20 = 5/20 for $P_2$

**$PR(P_2) = \frac{1}{5} + (\frac{1}{5})/4 = 5/20$**

## 14.3. Complete PageRank algorithm (用于解决Extreme Cases)

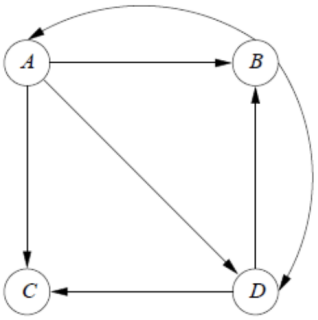


14.3.1. **Dead End (a page with no edges out)**

14.3.1.1. **Absorb PageRanks**

14.3.1.2. **PageRank => 0** for **any page that can reach the dead end (including the dead end itself)**

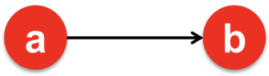


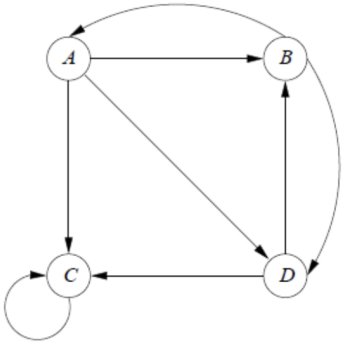


14.3.2. **Spider Trap (Group of pages with no edges going out of group)**

14.3.2.1. **Absorb all PageRanks (rank of C =>1, others =>0)**

14.3.2.2. **Surfer can never leave, once trapped**

14.3.2.3. **Can have > 1 such trap nodes** (group的大小可能>1)

14.3.3. 解决方法: **Taxation** (给每个page添加一个概率β, 表示在跳转的时候有$(1 - \beta)$的概率会随机跳转到任意某个其他page)

14.3.3.1. 改进后的公式: $r_j = (1 - \beta) + \beta \sum_{i \to j} \frac{r_i}{d_i}$, 通常β是介于0.8至0.9的数

## 14.4. Suggestions for improving PageRank

14.4.1. **Increasing the internal link in your site** (site内的in-link越多整个网站就越稳定, 你指向别的external page的时候分享出去的rank就越少)

14.4.2. **Use a hierarchical structure to highlight the root page** (可以理解为用tree的结构去维护一个site, 这样main page会获得最高的Rank)

14.4.3. 理论上不指向任何**external page**会给你带来最高的**Rank,** 但是不推荐这么做 (如果所有人都这么做, 网络将被分割成无数个小的block而不会互相连接)

★ 💥💥**Exam**可能会考**:** 要会应用Saty提供的计算**PageRank**的网页算出某个给定的图的**PR**

# 15. Snippets

## 15.1. 定义: 指搜索结果页面中的摘要或简介

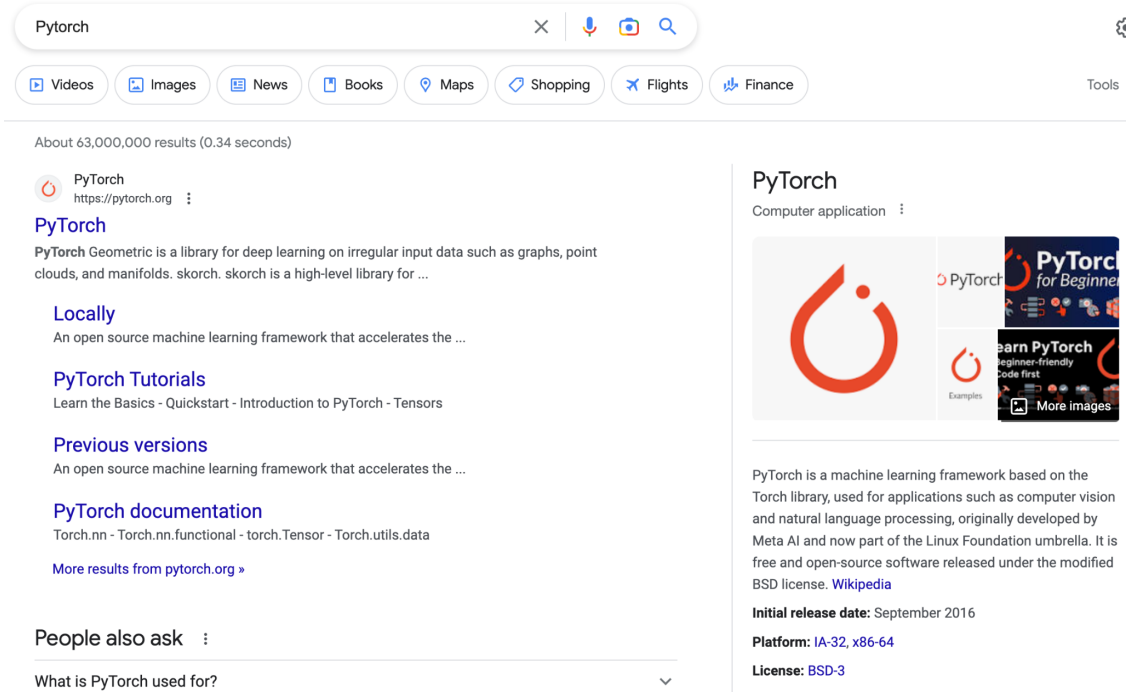


## 15.2. Feature Snippets

15.2.1. 定义: Feature Snippet通常位于搜索结果的顶部, 以突出显示与用户搜索意图相关的答案. 它们通常会直接回答用户的问题, 而不需要用户进入网页查找答案

15.2.2. 类型: **Paragraph**, **List, Table**

15.2.3. 内容来源: page的metadata; page的内容

## 15.3. Snippets Generation算法:

15.3.1. 流程:

15.3.1.1. 找到包含query terms的paragraphs

15.3.1.2. 对这些paragraphs进行打分, 找出分数最高的那一个paragraph

15.3.1.3. 返回这个paragraph中包含query terms的一小段话

15.3.1.4. 如果这个document有abstract或者conclusion, 可以直接选取这一部分作为15.3.1.3中需要的paragraph

15.3.2. Scoring:

15.3.2.1. 首先长度小于一定阈值的paragraph就是0分

15.3.2.2. 剩下的paragraph的公式: $Score_{k-th} = \beta_k + max(APL, MPL)$, 其中$Score_{k-th}$

表示第k段paragraph的分数, $\beta_k$表示位置参数, APL表示当前paragraph的长度, MPL表示所有paragraphs中的最长长度

### 15.4. Rich Snippets

15.4.1. 定义: Rich Snippets are normal Google search results with additional data displayed. This extra data is usually pulled from Structured Data found in a page's HTML. (简单来说就是在写网页的时候HTML里有一些tag可以添加为rich snippets) Common Rich Snippet types include **reviews**, **recipes** and **events**.

★ **Example: Without and with Rich Snippets:**

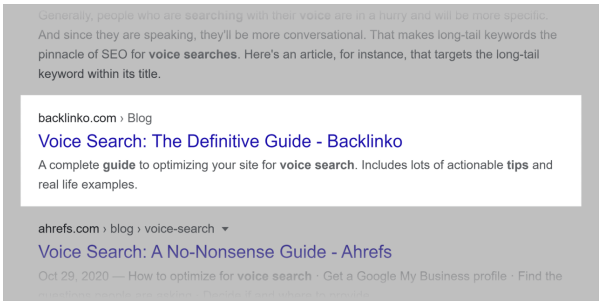


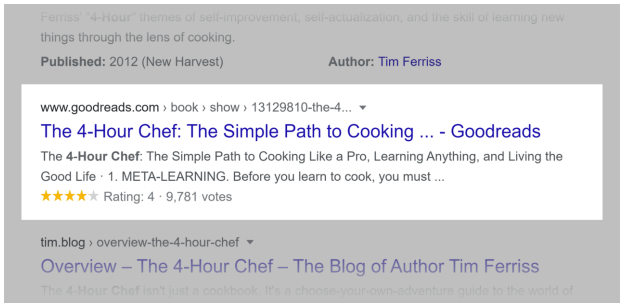


15.4.2. 优点:

15.4.2.1. 对于webmasters: Provides webmasters the ability to add useful information to their web search result snippets to help Google make sense of their bits.

15.4.2.2. 对于users: Provides more information to a user about the content that exists on page so they can decide which result is more relevant for their query.

15.4.2.3. 对于Google: Provides **additional traffic to a webpage** & **higher click through rate**

15.4.2.4. **Easy to add**. Just simple lines of existing HTML.

## 16. Query processing

### 16.1. 目的: Speeding up Indexed Retrieval

16.1.1. **Minimally return documents that contain the query terms**

16.1.2. **Top-ranking documents should be both relevant and authoritative**

16.1.3. **Determine what the user is actually trying to accomplish, even though the query may be vaguely stated**

### 16.2. 针对16.1.1的改进

16.2.1. **Consider only query terms with high-idf scores**

16.2.1.1. 例子: 对于catcher in the rye这个query, 只累加catcher和rye的cosine分数, 因为in和the这两个词的idf很低, 即在绝大多数文档都有出现, 他们对整体排名的贡献度很低

16.2.1.2. 好处: low-idf terms对应的postings会包含很多docs, 这么做可以从一开始就不考虑这些docs从而加速

16.2.2. **Consider only docs containing several query terms**

16.2.2.1. 例子: 假设query是 “Spatial Data Analysis”, 理论上我们会找包含 “Spatial”或 “Data”或 “Analysis”或 “Spatial Data”...的docs并且计算cosine分数然后排序返回给用户. 但是我们现在只找包含长度为2和3的term的docs (**only compute cosine scores for docs containing several of the query terms**)

16.2.2.2. 好处: 不用考虑很短的term, 这些term往往对应很多docs, 大大加快了速度; 同时easy to implement in postings traversal

16.2.3. **Introduce Champion Lists Heuristic**

16.2.3.1. 方法: Pre-compute for each dictionary term $t$, the $r$ docs of highest tf-idf in $t$'s postings (相当于对语料库里的每个term预处理出一个posting list, 这个list里只存tf-idf最高的$r$个文档), 这个list也叫champion list

★ **Note: r**有可能比**K (**返回给用户的文档数**)**小**(**因为**r**是在建立**index**的时候确定的**,** 而**K**是在**query**的时候确定的**); r**对于不同的**term**来说可以不一样

16.2.3.2. 好处: 在query的时候, 只需要计算在champion list里的docs的cosine score, 然后最后merge之后排序输出前K个给用户就行了, 需要考虑的文档数大大减小了

16.2.4. **High and Low lists Heuristic**

16.2.4.1. 方法: 相较于传统方法只维护一个postings list, 现在维护两个postings lists (可以想像一个为high一个为low, high即为champion list). 当拿到一个query时首先看high lists里包含的文档数有没有达到K: ①如果已经比K多了, 那就可以只用high lists来返回用户的query; ②如果比K少, 为了给用户一共K个结果, 就需要从low lists里再取若干个直到总数达到K

16.2.4.2. 好处: 既像16.2.3一样节省了时间, 又保证用户一定能得到一定数目的结果

★ **Note:** 这么做的前提是我们有某种方法把**inverted index**分成两个**tiers**

## 16.3. 针对**16.1.2**的改进

16.3.1. **Relevance**和**Authority**的定义

16.3.1.1. Relevance: **cosine scores**

16.3.1.2. Authority: 这个文档的权威性(可信度), 比如我写的page和NY Times写的page

肯定就是他写的Authority更高

16.3.2. 方法:

16.3.2.1. 定义一个$g(d)$表示某个document的**Authority**, $g(d) \in [0,1]$

16.3.2.2. 修改score的公式为: $score_{net}(q,d) = g(d) + cosine(q,d)$

16.3.2.3. 原来在posting lists里排序的顺序是按照DocID的, 现在改为按照$g(d)$从大到小排, 这样越权威的doc会出现在越靠前的位置 (前提是两个**docs**的**cosine score**相同)

## 16.4. Reverse Engineering of Google's query processing algorithm

16.4.1. 两家公司*Searchmetrics*和*Moz.com*通过检测相同query得到的结果随着时间和多个metrics(例如点击率)的变化在google search上的排序变化, 从而反向推断google的算法目前更看重哪些指标

## 16.5. Google Architecture

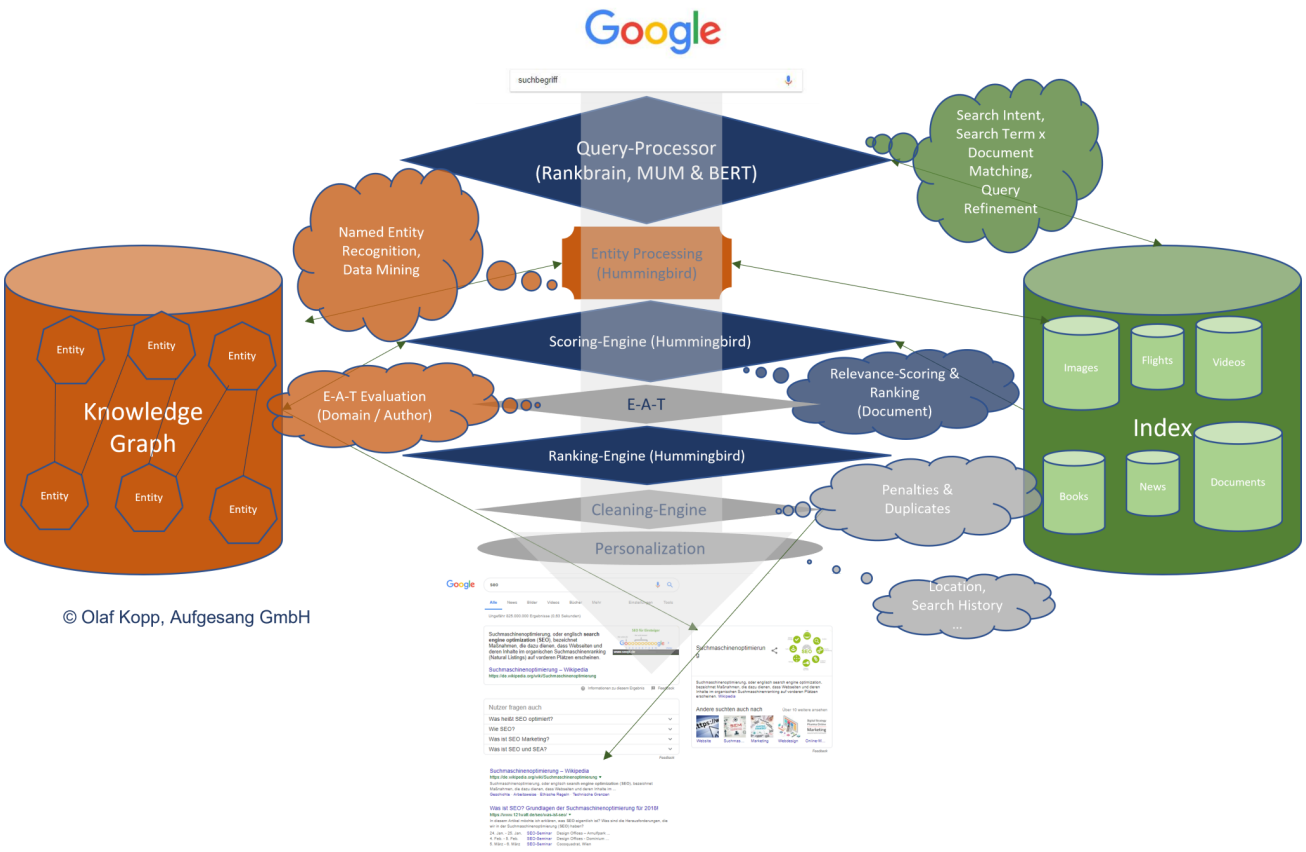


16.5.1. Identify Entity: **RankBrain**

16.5.1.1. 定义: RankBrain is a deep learning-based algorithm that is used after the

selection of an initial subset of search results (简单来说就是RankBrain会猜测用户真实想要搜索的内容, 比如搜索“美国的首都是哪里?”, 你的真实搜索意图是寻找美国的首都的名字, 而“哪里”这个关键词是否存在于目标网页上, 已经不再重要了)

16.5.1.2. 方法: RankBrain **maps keywords into entities** which are then looked for in the Knowledge Graph (将keywords和entities一一对应)

★ **Note: Entity-based和term-based的区别:** A purely term-based search engine would not recognize the difference in meaning of the search queries “red stoplight” and “stoplight red” because the terms in the query are the same, just arranged differently. Depending on the arrangement, the meaning is different. **An entity-based search engine recognizes the different context based on the different arrangement.** “stoplight red” is its own entity while “red stoplight” is a combination of an attribute and an entity “stoplight”

16.5.1.3. 流程: 可以将每个用户的一次搜索看成对RankBrain的一次训练 (记住这是一个deep learning的模型), 对于每一次搜索:

- RankBrain根据现有的权重对这个query输出一个搜索结果页
- RankBrain会观察用户对当前结果的态度 (用户是否点击了这些link, 用户对排序的顺序是否满意)
- RankBrain会根据得到的用户反馈更新自己的权重 (假设搜索同一个东西的很多用户对推荐的列表的后几个很感兴趣, uprank这些link)

16.5.1.4. Google claims that RankBrain is **the third most important factor** in their ranking algorithm (**links/words being numbers 1 and 2**)

16.5.2. Entity Recognition: Google的Knowledge Graph很大程度上依靠wikipedia的strctured content. (🌰: 搜索 “Apple founder”, 首先Identify Entity这一步会将这个query识别为 “Apple公司的founder”, 然后google去自己的的Knowledge Graph中Apple这个词条下founder的信息, 找到是Steve Jobs. 所以最后返回给用户的结果是和Steve Jobs相关的. 而**Steve Jobs**甚至完全没在用户的**query**中出现)

# 17. Auto correction/completion

## 17.1. Auto correction两个主要任务

17.1.1. Spelling Error **Detection**: need a big dictionary; using context may be necessary

17.1.2. Spelling Error **Correction**: **edit distance algorithm** or **n-gram matching**

## 17.2. 三种Spelling Errors

17.2.1. Non-word errors: e.g. graffe → giraffe

17.2.2. Typographical errors: e.g. three → three (**both are legal words**)

17.2.3. Cognitive errors: e.g. your → you're

## 17.3. Basic Spelling Correction Algorithm的步骤

17.3.1. Create a dictionary and encode it for fast retrieval

17.3.2. 当接收到一个query时, 检查这个query中每个**word**以及**n-gram**是否在dictionary里. 如果是则判断不需要correction; 如果不是则找possible character edits (这里用 **Levenshtein algorithm**来算距离)

★ **Note:** n-gram在这里的存储结构是字典树 **(tire)**, 查找复杂度为**O(k)**, k为query长度

★ **Levenshtein algorithm**: 计算两个word之间的**edit distance**, 其中有三个操作 (insertion, deletion, change), 每个操作的距离为1 (e.g. sitten到setting的距离为3)

- Levenshtein algorithm实际上是一个动态规划, 假设一个函数edit(i, j), 它表示第一个字符串的长度为i的子串到第二个字符串的长度为j的子串的编辑距离
- 转移方程:

$$edit(i,j) = \begin{cases} 0, & \text{if } i = 0 \text{ and } j = 0 \\ j, & \text{if } i = 0 \text{ and } j > 0 \\ i, & \text{if } i > 0 \text{ and } j = 0 \\ \min\{ & edit(i-1,j)+1, \\ & edit(i,j-1)+1, \\ & edit(i-1,j-1)+f(i,j)\}, \\ & \text{if } i \geq 1 \text{ and } j \geq 1 \end{cases}$$

, 其中, 当第一个字符串的第$i$个字符不等于第二个字符串的第$j$个字符时, $f(i,j) = 1$; 否则,$f(i,j) = 0$

- Levenshtein algorithm的一个实现
- 为edit distance增加权重: 为什么**?** → 现实世界中某些字母之间更容易被拼错(e.g. A和E). 建立一个混淆矩阵(**confusion matrix**)来记录不同的字母之间被互相混淆的次数, 这个次数就可以作为考量correction时的一个权重.

17.3.3. 通过Levenshtein algorithm算出距离错误term为k(k=1 or 2)的字典里的term作为替换掉错误的term作为candidates. 这样candidates会是若干个新的n-gram

17.3.4. 用**Noisy Channel Model**计算出每个candidate是用户想搜的内容的probability, 选取最高的那个进行搜索代替用户原来的query

★ **Noisy Channel Model**: 设计理念为, 拼写错误是由正确的文本经过"Noisy Channel"被混淆的结果. 通过建模这个通道, 可以逐词排查, 寻找最接近的单词. 这种有噪通道模型属于贝叶斯推断(Bayesian inference), 因此概率分布遵循贝叶斯原则.

- 概率公式:

$$P(\text{candidate word} \mid \text{received word}) = \frac{P(\text{received word} \mid \text{candidate word}) \times P(\text{candidate word})}{P(\text{received word})}$$

其中, $P(candidate\ word \mid received\ word)$ 表示在收到word后, 正确的word为candidate word的概率

### 17.4. Auto-completion

17.4.1. 在17.3.2中我们讲过存储n-gram的结构是tire, 这也是auto-complete的思路. 匹配到某个candidate的时间为O(k), k为candidate的n-gram的长度. 然后再按照probability从高到低显示给用户

## 18. Question answering

### 18.1. Question Answering 3 phase block architecture

18.1.1. 主要关注Question Processing和Answer Extraction. Passage Retrieval相当于是inverted index的过程

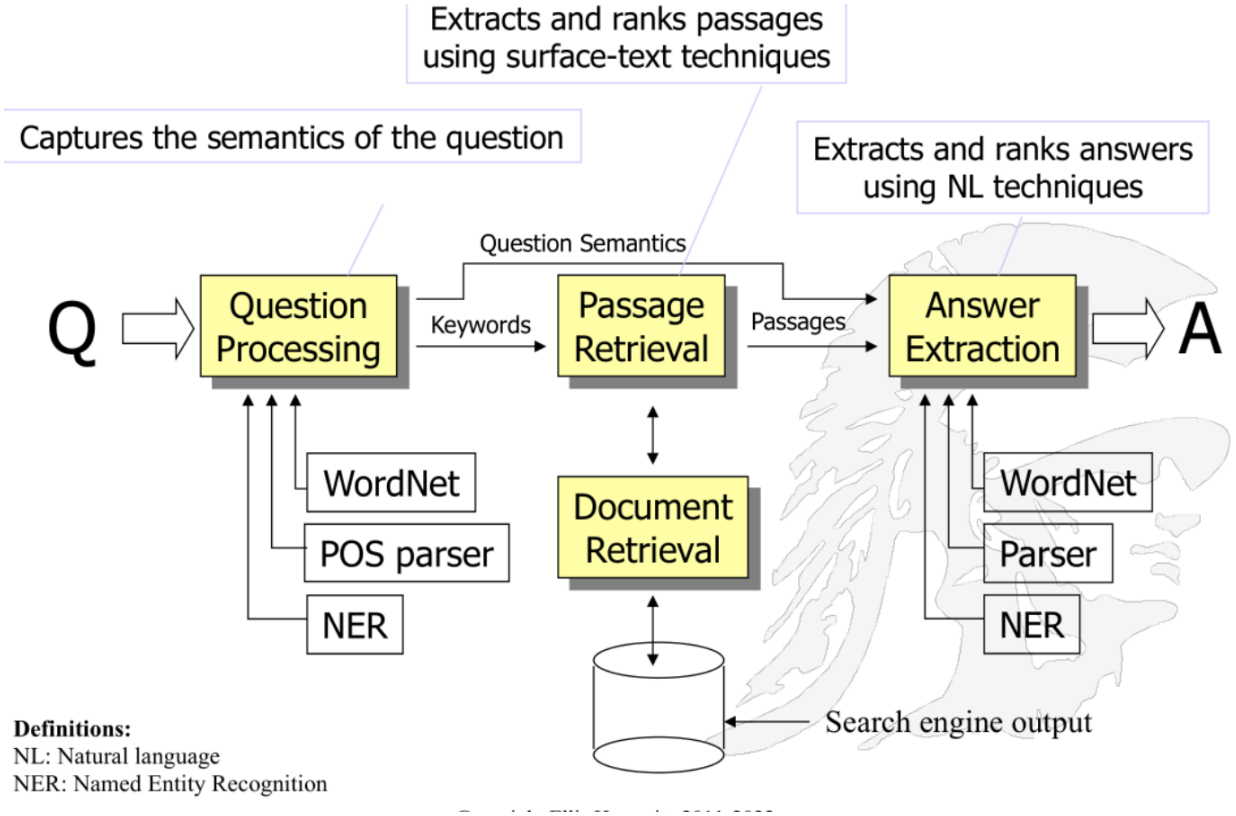


## 18.2. Question Processing

18.2.1. **Part-of-speech tagging** (POS parser)

18.2.1.1. 将一个问题里的每个word都标上词性, 从而判断哪些词容易成为keyword. 同时, POS标记一旦手动完成, 就可以在计算语言学的上文中使用通过Markov Model求出可能的下文

★ **Note:** 这个方法准确率很低, 因为很多时候**question**里的词的顺序不是一定的. 比如有人的问题可能是 **"**今天天气如何**?",** 而有人的问题可能是**"**天气怎么样今天**?".** 词的顺序不定性会导致**Markov Model**失效

18.2.2. **Named Entity Recognition** (NER) 也叫 **Semantic Relations (**通常用**BERT**实现**)**

18.2.2.1. 将问题中的词进行entity的分类 (可以参考下面🌰)

contentSkip to site indexPoliticsSubscribeLog InSubscribeLog InToday's PaperAdvertisementSupported ORG byF.B.I. Agent Peter Strzok PERSON , Who Criticized Trump PERSON in Texts, Is FiredImagePeter Strzok, a top F.B.I. GPE counterintelligence agent who was taken off the special counsel investigation after his disparaging texts about President Trump PERSON were uncovered, was fired. CreditT.J. Kirkpatrick PERSON for The New York TimesBy Adam Goldman ORG and Michael S. SchmidtAug PERSON . 13 CARDINAL , 2018WASHINGTON CARDINAL — Peter Strzok PERSON , the F.B.I. GPE senior counterintelligence agent who disparaged President Trump PERSON in inflammatory text messages and helped oversee the Hillary Clinton PERSON email and Russia GPE investigations, has been fired for violating bureau policies, Mr. Strzok PERSON 's lawyer said Monday DATE .Mr. Trump and his allies seized on the texts — exchanged during the 2016 DATE campaign with a former F.B.I. GPE lawyer, Lisa Page — in PERSON assailing the Russia GPE investigation as an illegitimate "witch hunt." Mr. Strzok PERSON , who rose over 20 years DATE at the F.B.I. GPE to become one of its most experienced counterintelligence agents, was a key figure in the early months DATE of the inquiry.Along with writing the texts, Mr. Strzok PERSON was accused of sending a highly sensitive search warrant to his personal email account.The F.B.I. GPE had been under immense political pressure by Mr. Trump PERSON to dismiss Mr. Strzok PERSON , who was removed last summer DATE from the staff of the special counsel, Robert S. Mueller III PERSON . The president has repeatedly denounced Mr. Strzok PERSON in posts on

## 18.3. Answer Extraction

### 18.3.1. NLP Extraction (build Knowledge Graph)

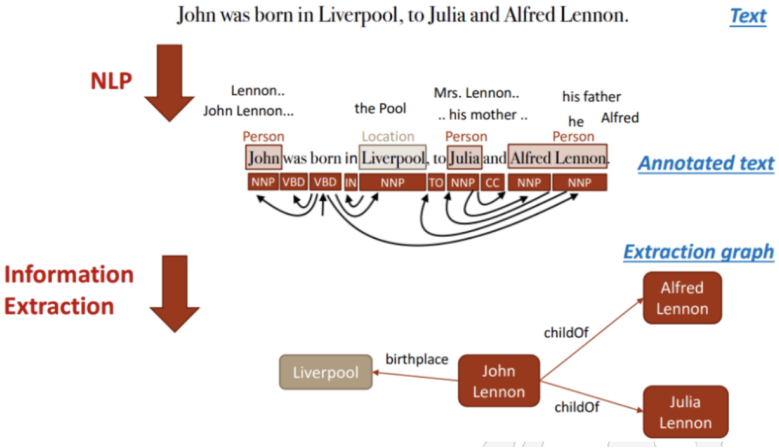

## ☐ 03/28/2023课堂扩展内容: Why language question answering is so easy for human but so hard for AI?

- ☐ 可以把问题转化为人、动物、AI之间理解问题的模式有什么区别
- ☐ 1. 信息的理解被分为两个部分: non-symbolic和symbolic. Symbolic表示看到的或者听到的信息被转化为某个我们理解的entity; non-symbolic表示个人的经历以及直觉.
- ☐ 2. Human是既具有symbolic又具有non-symbolic的能力的. 比如开车看到stop sign的时候如果一个人理解英语他就能知道这个符号代表着停止, 这就是symbolic. 而他学过开车所以他知道看到stop sign应该怎么做是符合交规的, 这就是non-symbolic.
- ☐ 3. Animal是不太具有symbolic, 只有non-symbolic的能力的. 比如狗或者猫只能在训练下听懂极少数的命令, 但是它们知道饿的时候该找什么吃.
- ☐ 4. AI是只具有symbolic而完全不具有non-symbolic的能力的. 你可以给一个AI对任意一个term一个全新的定义, 对它来说没有任何的区别. 它们并不能感知这些定义之后的真实意义, 比如你可以让AI理解stop就是停止, 但是停止这个动作的意义以及为什么看到stop sign要停止对于AI来说是没有意义的, 也是不被需要的. 因此AI是没有情感的
- ☐ 因此, 当你问AI一个问题时, 它必须要和数据库里的定义有确切的联系才能让AI做出相应的回答, 而AI不会为你的问题做出任何预设 (比如你问AI“后天天气怎么样?”, AI并没有时间观念, 所以首先要查询今天的日期, 然后它需要把“天气”量化为温度、湿度、气候等指标才能对你做出回答)

# 19. Clustering (for classification, 主要讨论在document领域)

## 19.1. 如何用Clustering来做Classification问题? (Clustering是unsupervised learning而Classification是supervised learning)

19.1.1. 对数据进行**Clustering**

19.1.1.1. **How to represent the document?** → vector space; point space

19.1.1.2. **How to compute similarity/distance** → cosine similarity; euclidean distance

19.1.1.3. **How many clusters?** → fixd priori number; data driven

19.1.1.4. Avoid **a cluster to be too large** or **too small** (某些用户得到的document过多或者过少)

19.1.2. 对每一个得到的**cluster**进行**label (**总结出**cluster**中的通用关键词**),** 这样每个**cluster**实际上就变成了一个**class**

19.1.2.1. Hard clustering: 每个文档只能属于一个cluster (easier)

19.1.2.2. Soft clustering: 每个文档可以属于多个cluster

19.1.3. 计算出每个**cluster**的**boundary (**每个**cluster**就变成了一个多边形区域**)**

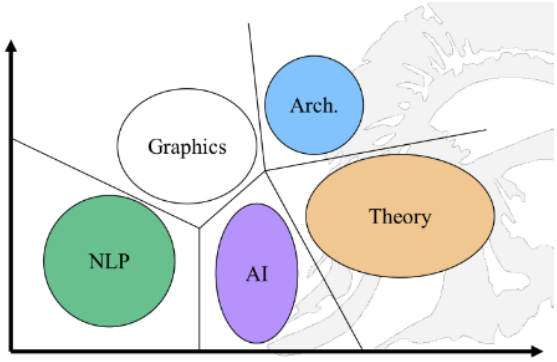


19.1.4. 对于新输入的需要分类的文档**,** 实际上只是把它归到某一个**cluster**里就相当于完成了分类

19.1.4.1. 如果一个document恰好坐标在boundary的线上, 那它就会被同时归为多个类

## 19.2. K-means (partitioning-based algorithm)

19.2.1. 特点: k的值是提前定好的

19.2.2. 步骤:

19.2.2.1. 随机取k个点作为中心

19.2.2.2. 计算所有点到这两个点的距离, 到哪个点距离小就归为哪个簇

19.2.2.3. 计算新的中心坐标(x,y各取平均)

19.2.2.4. 重复19.2.2.2, 19.2.2.3过程直到新的中心坐标和上一轮一模一样

19.2.3. 复杂度: **O(iknm)**, 其中i是iteration次数, k是cluster个数, n是point个数, m是attribute数量

## 19.3. Hierarchical Clustering algorithm

19.3.1. 类型: **Agglomerative** (bottom up)和**Divisive** (top down)

19.3.2. 步骤: Repeatedly combine two nearest clusters

★ **How to compute the distance between two clusters?**

- **Center of Gravity** (compute the distance between the **two centroids** of the cluster)
- **Average Link** (Compute the **mean distance** between all pairs of points across the two clusters)
- **Single Link** (Compute the distance between **the two closest points** in the two clusters)
- **Computele Link** (Compute the distance between **the two furthest points** in the two clusters)

# 20. Classification Extension

## 20.1. KNN (已经在here进行了补充)

## 20.2. Rocchio (之前讲的是简化版, 在here) for Relevence Feedback

20.2.1. 问题: 之前讲的*Rocchio*算法是通过计算*query*到每个*class centroid*的距离, 选择最近的那个*centroid*作为新的*query*以一个范围去找最相关的*document*返回给用户. 假设现在有相关文档和不相关文档两个类别, 分布如右图所示, 其中圆点代表相关文档, 叉代表不相关文档. 我们就会选择(1.5, 1.5)这个centroid作为我们的新query. 但是这里如果以(1.5, 1.5)为中心, 不相关文档和相关文档到这个点的距离是一样的, 我们仍然会返回不相关文档给用户.

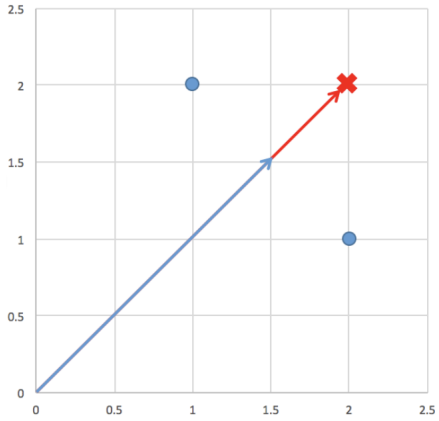


20.2.2. 解决方法: 添加Relevence Feedback, 用相关文档的质心减去不相关文档的质心, 使新query这个向量稍微偏移一点, 使它虽然离相关文档远了一点, 但是离不相关文档远的更多

20.2.2.1. 公式: $\vec{q}_{opt} = \alpha\vec{q}_0 + \beta\frac{1}{|C_r|}\sum_{d_j \in C_r}\vec{d}_j - \gamma\frac{1}{|C_{nr}|}\sum_{d_j \in C_{nr}}\vec{d}_j$, 其中$q_0$为用户输入的query, $C_r$为相关文档的集合, $C_{nr}$为不相关文档的集合, $\alpha, \beta, \gamma$为factor参数.

★ **Example:** 下图表现了添加偏移之后的效果

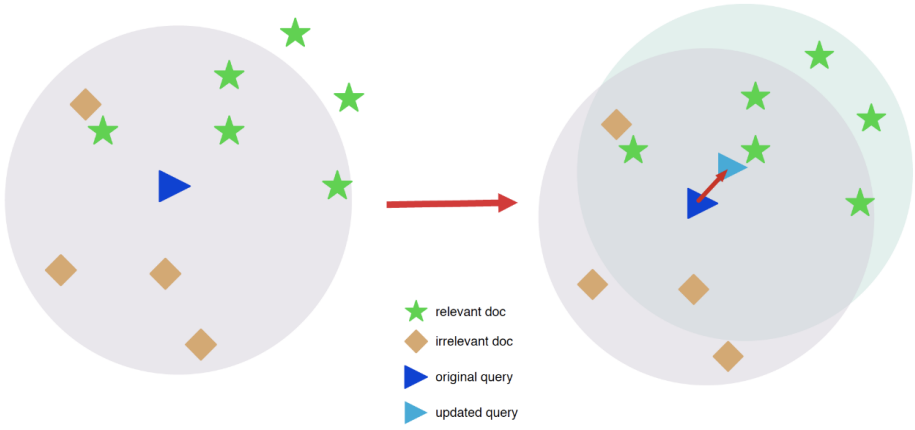

# 21. Recommendation System

## 21.1. Formal Model of the recommender system

- $C$ = set of Customers
- $S$ = set of Items
- Utility function $u$: $C \times S \rightarrow R$
  - $R$ = set of ratings
  - $R$ is a totally ordered set
  - e.g., **0-5** stars, real number in **[0,1]**

| | Avatar | LOTR | Matrix | Pirates |
|---|---|---|---|---|
| Alice | 1 | | 0.2 | |
| Bob | | 0.5 | | 0.3 |
| Carol | 0.2 | | 1 | |
| David | | | | 0.4 |

21.1.1. Utility matrix: 根据utility function得到的矩阵, 是一个item和customer的映射

21.1.2. Prediction: 注意到上图有很多空白部分, 预测的目的就是判断该不该推荐某物给某人. 设定一个推荐阈值很重要, 不易推荐过多结果给用户.

## 21.2. Content-based Recommender Systems(consider single user)

21.2.1. 特点:

21.2.1.1. Use **characteristics** of an item

21.2.1.2. Recommend items that have **similar content to items user liked in the past**

21.2.1.3. Or items that **match predefined attributes of the user**

21.2.2. 步骤:

21.2.2.1. 定义一些features, 构造item profiles(vector) **(item-based)**

21.2.2.2. 用相同的**features**构造user profiles(vector) **(user-based)**

21.2.2.3. 用**Cosine distance**计算user到item的距离, 用分类算法匹配最近的user-item

21.2.3. 优点:

21.2.3.1. **No need for data on other users**: No **cold-start** (for item) or **sparsity problems** (i.e., new items can receive recommendations)

21.2.3.2. **Able to recommend to users with unique tastes**

21.2.3.3. **Able to recommend new & unpopular items**: No **first-rater problem** (i.e., new products never have been rated, therefore they cannot be recommended)

21.2.3.4. **Able to provide explanations**: Can provide explanations of recommended items by listing content-features that caused an item to be recommended

21.2.4. 缺点:

21.2.4.1. **Finding the appropriate features is hard**

21.2.4.2. **Recommendations for new users**

21.2.4.3. **Overspecialization**: Never recommends items outside user's content profile;

People might have multiple interests; **Unable to exploit quality judgments of other users (don't use ratings!)**

### 21.3. Collaborative filtering (consider other users)

21.3.1. 特点:

21.3.1.1. Build a model from **a user's past behavior** (e.g., items previously purchased or rated), and **similar decisions made by other users**

21.3.1.2. Use the model to predict items that the user may like

21.3.1.3. Collaborative: **suggestions made to a user utilizing information across the entire user base (**用整个用户群体作为参考推荐东西给个体**)**

21.3.2. 两种类型(user-user, item-item)

21.3.2.1. In theory, user-user and item-item are dual approaches

21.3.2.2. In practice, **item-item outperforms user-user** in many use cases

21.3.2.3. Items are "simpler" than users because items belong to a small set of "genres", but users have varied tests.

## 22. Assorted topics (主要考如何应用这些算法or模型)

### 22.1. Image understanding and search

22.1.1. 经典数据集: **ImageNet**

22.1.2. 经典Computer Vision算法: **CNN**

22.1.3. 新的算法: **Vision Transformers (ViT)**: 将输入图像分割成若干个固定大小的小块(称为token). 然后, 每个图像块被转换成一个一维向量, 这些向量作为transformer模型的输入序列. 模型通过自注意力机制(self-attention)和多层感知机(MLP)来捕捉和学习图像中的局部和全局信息

### 22.2. Code search (tree + Inverted Indexing + Delta Indexing + deduplication + MinHash)

### 22.3. Location Based Search (LBS)/Proximity Search (PS)

22.3.1. 概念: using location data where the query originates, and using that to return responses.

22.3.2. 如何快速反应动态**GPS**网络下的实时信息**?** → A Unified Approach to Spatial Proximity Query Processing in Dynamic Spatial Networks: 文章主要贡献是提出了用cache存储动态网络中共用路径的状态来加速**query** (比如两个人同时在使用google map, 分别从两个地方出发要到两个不同的地方. 但是他们各自的路径中

有一条路(称为X)是都会走的, 那么在第一个人搜索的时候网络处理出X的当前情况, 第二个人在搜索的时候就可以用cache里存的X的情况, 不同再处理一次)

22.3.3. 如何防止邻近服务中的用户隐私泄露? (某些公司会通过手机定位你的确切地址, 某些交友应用可以将你的定位泄露给其他用户) → Where's Wally? Precise User Discovery Attacks in Location Proximity Services: 文章介绍了一种攻击"Wally"能利用APP中邻近服务的漏洞得到其他用户的定位, 并且提出了保护的方法, 包括对用户的位置信息进行模糊化处理 (只给APP一个框框, 表示用户位置在这个框内, 而不是一个精确的点)

### 22.4. Similarity search using vector DBs

22.4.1. 将传统的database (e.g. table)映射到**vector space** (每一列成为一个维度). 这样每一行, 也就是每个instance, 都会被表示为一个vector. 然后就可以在vector space上很容易用cosine similarity计算不同的instance之间的相似度

### 22.5. LDA, for topic modeling

22.5.1. LDA假设每个文档都包含了多个主题, 而每个主题则对应一组词汇分布. 对于每个文档中的每个单词, LDA首先将其随机归为某个主题, 并根据该主题的词汇分布随机选择一个单词代表主题. 通过不断迭代更新主题词汇分布和文档主题分布, LDA最终可以得到每个主题的词汇分布和每篇文档的主题分布.

★ **Note1:** LDA是一个**unsupervised learning algorithm** (每个主题具体是什么内容要人工观察分析得到)

★ **Note2:** 一篇文章可能包含多个主题, 其中每个主题所占的比例不同 (通过主题词汇的统计得到比例)

### 22.6. ANN (Approximate Nearest Neighbors)

22.6.1. 意义: KNN的查询一个query的复杂度是O(n), 当n特别大的时候就会很慢. 我们希望在损失一定准确度的情况下大大提高查询的速度.

22.6.2. **Annoy Algorithm**

22.6.2.1. 用二叉树结构实现, 复杂度为**O(log(n))**

22.6.2.2. 流程:

- 开始的时候, 在数据集中随机选择两个点, 然后用它们的中垂线来切分整个数据集. 可以理解为成为了二叉树的两个分叉
- 以此类推继续分割, 直到每一个平面区域最多拥有**K**个点为止 (这里的K是人为定义的)
- 下面, 新来的一个点, 通过对二叉树的查找, 我们可以找到所在的子平面, 这个平面里面最多有**K**个点

22.6.2.3. 问题:

- 我们想要TopK的点, 但是该区域的点数量不足K
- 真实的TopK中部分点不在这个子平面

22.6.2.4. 解决方法:

- 设定一个阈值, 如果查询的点与二叉树中某个节点比较相似, 那么就同时走两个分支, 而不是只走一个分支 (即最后会得到多个子平面的并集)
- 构建多棵树, 采用多个树同时搜索的方式, 得到候选集TopM(M>K), 然后对这 M 个候选集计算其相似度或者距离, 最终进行排序就可以得到近似TopK的结果

22.6.3. **Faiss Algorithm**

22.6.3.1. Inverted File Index: 一种数据库预处理技术, 先把数据库中所有向量通过K-means聚类算法划分成多个cluster, 每个cluster有自己对应的index

22.6.3.2. 后续在进行数据库搜索时, 先找query所对应的目标cluster (比较query到每个centroid之间的距离), 再在这个cluster内做穷举比对 (每个cluster相当于22.6.2中的一个子平面)

## 22.7. Task-specific fine-tuning

22.7.1. 根据特定的任务和数据训练针对性的模型 (**narrow and deep**)

## 22.8. Task-specific embedding

22.8.1. 目标: Multiple NLP tasks can be handled by a system, if it embeds a document in a way that's related to the task (每一个任务的特点可能都不一样, 但是经过统一的embed之后可以用同一种量化标准来表示这些任务的数据. 这样就可以训练出一个模型同时可以处理多种task)

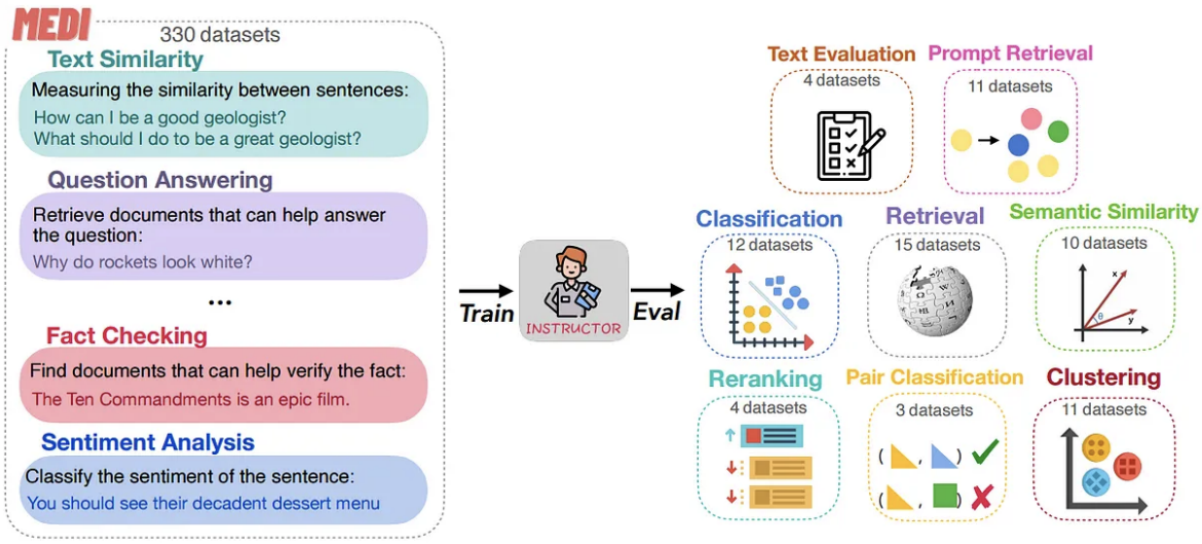

### 22.9. LLM+tasks+memory -> LLM + Langchain + Vector DB

#### 22.9.1. OPL (OpenAI + Pinecone + Langchain)

★ **Example**: LLMs such as GPT-4 are 'pretrained' (that is the 'P') with a large amount of language data. For more precise answers, they need to be 'fine tuned' with specific domain-related (eg medical, legal...) language, OR, be chained to a custom DB that can be accessed by the GPT. In this context, **what is the 'OPL stack'? Describe in your own words, sticking to what we discussed in class (high level description is fine)**.

★ **A:** OPL stands for OpenAI, Pinecone, and Langchain. OpenAI provides API access to powerful LLMs and also provides embedding models to convert text to embeddings. Pinecone provides embedding vector storage, semantic similarity comparison, and fast retrieval. Langchain allows users to build their own LLM applications, and can be used to fine-tune the models on domain-specific data or connect them to external databases.

### 22.10. Reducing Dimension

#### 22.10.1. t-SNE

22.10.1.1. 基本思路: 用条件分布的概率表示高维度中两点之间的相似性, 希望拟合的分布是t分布 (类似正态分布)

#### 22.10.2. Manifold learning (也用于计算 similarity)

22.10.2.1. 基本思路: 用非线性算法表达两点之间的距离从而降维

★ **Example:** 如右图所示, 在一个卷起来的曲面内如果我们用两个点的空间几何距离表示他们的距离其实是不准确的. 我们应该把这个曲面展成一个平面才能表达这两个点的真实距离

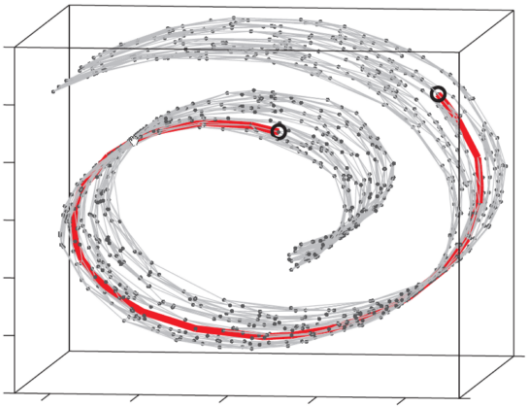

### 22.11. NeRF

22.11.1. 思路**:** 通过机器学习实现通过2D图像的信息生成3D模型

22.11.2. 应用**: pokemon go (AR games); immersive views (Google Map)**

## 23. Legal Aspects

### 23.1. Bias in Search Results

23.1.1. 问题**:** 搜索引擎的公司更偏向于展示和自己有经济利益的网站 (e.g. Google更喜欢展示youtube, 而MS更喜欢展示msn)

## 23.2. GDPR (General Data Protection Regulation)

### 23.2.1. What is GDPR?

23.2.1.1. **Lawfulness, fairness and transparency** — Processing must be lawful, fair, and transparent to the data subject.

23.2.1.2. **Purpose limitation** — You must process data for the legitimate purposes specified explicitly to the data subject when you collected it.

23.2.1.3. **Data minimization** — You should collect and process only as much data as absolutely necessary for the purposes specified.

23.2.1.4. **Accuracy** — You must keep personal data accurate and up to date.

23.2.1.5. **Storage limitation** — You may only store personally identifying data for as long as necessary for the specified purpose.

23.2.1.6. **Integrity and confidentiality** — Processing must be done in such a way as to ensure appropriate security, integrity, and confidentiality (e.g. by using encryption).

23.2.1.7. **Accountability** — The data controller is responsible for being able to demonstrate GDPR compliance with all of these principles.

## 23.3. IP (Intellectual property)

### 23.3.1. 四类IP:

23.3.1.1. **copyright** (for literary works, art, and music)

23.3.1.2. **patents** (for inventions and processes)

23.3.1.3. **trademarks** (for company and product names and logos)

23.3.1.4. **trade secrets** (for recipes, code, and processes)

★ 额外思考**:**

1. AI生成的画作, 音乐如何侵犯了人类相关行业工作者的权利?
2. Deepfake可能有什么糟糕的影响?